

CHALLENGE FIAP 2026 · LOCAWEB · PROJETO CRONOS

MANUAL DE CONCEITOS · VOLUME ÚNICO

CIÊNCIA DE DADOS

aplicada à previsão de incidentes

O TERRENO · OLHAR ANTES DE MODELAR

PREVER O QUE VEM · APONTAR O CASO

MEDIR DIREITO · COSTURAR

O RIGOR E O PEDIDO

CONTEÚDO

Sumário

PARTE I		<i>O terreno</i>	
I	Dado, informação e modelo		1
II	Descrever, prever, decidir		6
III	A base e o recorte que define tudo		11
PARTE II		<i>Olhar antes de modelar</i>	
IV	Para que serve a análise exploratória		16
V	Distribuição, média e a tirania da cauda		21
VI	Concentração e Pareto		26
VII	Sazonalidade e efeito calendário		31
VIII	Mudança de regime e anomalia		36
PARTE III		<i>Prever o que vem</i>	
IX	O que é uma série temporal		41
X	Tendência, sazonalidade e resíduo		46
XI	O baseline: a régua que todo modelo tem que vencer		51
XII	Prophet por dentro		56
XIII	Erro e incerteza		61
XIV	Validação temporal		66
PARTE IV		<i>Apontar o caso</i>	
XV	Classificação: prever um rótulo		71
XVI	Features: transformar o mundo em coluna		76
XVII	Vazamento: o erro que só aparece em produção		81
XVIII	Regressão logística		86

PARTE V	<i>Medir direito</i>	
XXIX	Evento raro e por que a acurácia mente	91
XX	Matriz de confusão e o limiar de corte	96
XXI	ROC, AUC e PR-AUC	101
XXII	Curva de ganho e a leitura por triagem	106
XXIII	Calibração e explicabilidade	110

PARTE VI	<i>Costurar</i>	
XXIV	Aprendizado não supervisionado e clusterização	115
XXV	Quando o modelo complexo não paga	120
XXVI	Índice composto: construir uma nota	125
XXVII	Compor modelos sem extrapolar nenhum	130

PARTE VII	<i>O rigor e o pedido</i>	
XXVIII	Hipótese, teste e o valor do resultado negativo	135
XXIX	Reprodutibilidade	140
XXX	Da pergunta ao método	144

I

PARTE PRIMEIRA

O terreno

-
- I Dado, informação e modelo
 - II Descrever, prever, decidir
 - III A base e o recorte que define tudo
-

CAPÍTULO I

Dado, informação e modelo

o que a gente está fazendo, antes de fazer

Três palavras que a gente usa como sinônimo e não são. A diferença entre elas explica por que um relatório cheio de número pode não servir pra nada, e por que meia dúzia de colunas às vezes vale mais que a base inteira.

§1 Dado não é informação

Um dado é um registro bruto. Na base do Cronos, uma linha inteira é isto: incidente aberto em 14/03/2025 às 09:12, prioridade 3, produto Cloud Server, origem Monitoramento, encerrado no dia seguinte. Sozinha, essa linha não responde nada. Ela só existe.

Informação é o dado depois que alguém fez uma pergunta. "Em março, 62% dos incidentes P3 do Cloud Server passaram de 8 horas" é informação, porque tem uma pergunta escondida dentro: *quanto tempo esses incidentes demoram?* Sem a pergunta, os dados ficam ali parados.

E existe um terceiro degrau, que é onde o trabalho realmente vale: a decisão. "Vou colocar mais um analista no plantão de terça" é decisão. Ela consome informação, mas não é informação.

A base tem 122.543 linhas. Ela não tem 122.543 informações — tem as que as nossas perguntas conseguiram extrair. Umas poucas dezenas. O resto continua sendo dado bruto até alguém perguntar alguma coisa.

§2 O que é um modelo

Modelo é uma simplificação da realidade, feita de propósito, para responder um tipo específico de pergunta. A palavra-chave é *de propósito*: o que o modelo joga fora é uma escolha, não um descuido.

Um modelo estatístico faz exatamente isso com número. Ele joga fora quase tudo do incidente — o texto da descrição, o nome do analista, a conversa registrada no chamado — e fica com meia dúzia de colunas. Se essas colunas forem as certas para a pergunta, o modelo funciona mesmo ignorando 95% do que existe no ticket.

NA VIDA REAL

O mapa do metrô de São Paulo está errado. As distâncias não são proporcionais, as linhas não são retas, as estações não estão nas coordenadas geográficas certas. Mesmo assim ele é melhor que uma foto de satélite para responder "como eu chego da Sé à Vila Madalena".

Ele jogou fora a geografia inteira e ficou só com o que importa pra pergunta: a ordem das estações e onde as linhas se cruzam. Se a sua pergunta fosse "quantos quilômetros são", o mapa seria péssimo e a foto de satélite, ótima. O modelo bom é o modelo certo *para a pergunta*.

§3 As três peças de qualquer modelo

Não importa se é uma regressão de três linhas ou uma rede neural gigante: todo modelo tem as mesmas três peças, e vale saber apontar cada uma antes de escolher a técnica.

O modelo de risco do Cronos, preenchido nas três peças:



Fig. 1.1 As três peças, com o modelo de risco de OLA preenchido em cada uma. O dado de treino fica fora do fluxo porque ele não participa da previsão do dia a dia: ele só existiu uma vez, quando a regra foi aprendida.

A peça que mais gente esquece é a de baixo. O mecanismo não caiu do céu: ele foi extraído de um histórico. Se o histórico mudar de comportamento, a regra continua a mesma e passa a errar sem avisar. Boa parte dos problemas que a gente teve no projeto é uma variação desse tema.

GLOSSÁRIO

Feature. Uma coluna de entrada do modelo. Em português: variável, característica, atributo. Todo mundo diz feature.

Alvo (ou target). A coluna que o modelo tenta acertar. No Cronos: quantos incidentes amanhã, ou este incidente vai violar o OLA.

Treinar. Mostrar ao algoritmo um monte de casos com a resposta certa, para ele calcular os pesos. Uma vez só, não a cada previsão.

§4 "Todo modelo está errado; alguns são úteis"

A frase é do estatístico George Box, de 1976, e não é humildade acadêmica. É critério de avaliação. A pergunta certa nunca é "o modelo está certo?", porque a resposta é sempre não. A pergunta é: *ele está errado o suficiente para estragar a decisão que eu vou tomar com ele?*

Isso muda tudo, porque a mesma margem de erro pode ser aceitável e inaceitável ao mesmo tempo, dependendo de quem pergunta.

NO CRONOS · O MESMO ERRO, DUAS RESPOSTAS

Nosso modelo de volume erra, em média, **11,8 incidentes por dia** na série P3, que roda a cerca de 55 por dia. Errado? Muito. Inútil?

- Para decidir se a semana entra em patamar alto ou baixo, e escalar plantão a partir disso: serve.
- Para decidir se um chamado específico vai estourar hoje: não serve, e nem foi feito pra isso.

Mesmo modelo, mesmo erro, duas conclusões opostas. Foi justamente por causa dessa distinção que o projeto precisou de um segundo modelo, o de risco por incidente.

COMO PEDIR

"Antes de escolher a técnica, escreve as três peças: qual é a entrada, qual é a saída e qual decisão muda com essa saída. Se a terceira não tiver resposta, a gente não faz o modelo."

REVISÃO RÁPIDA

- Dado é registro bruto; informação é dado depois de uma pergunta; decisão é o degrau que justifica os outros dois.
- Modelo é simplificação proposital. O que ele ignora é escolha, não descuido.
- Três peças: entrada, mecanismo, saída — mais o dado de treino, de onde o mecanismo saiu.
- A pergunta de avaliação não é "está certo?", é "está errado a ponto de estragar a decisão?".
- Erro de 11,8/dia serve para dimensionar semana e não serve para apontar chamado. Daí virem dois modelos, não um.

CAPÍTULO II

Descrever, prever, decidir

os três andares da análise, e onde quase todo projeto para

Toda análise de dado mora em um de três andares. Subir de andar custa muito mais trabalho do que parece, e a maior parte dos projetos de dados no mercado nunca sai do primeiro. Saber em qual andar você está evita prometer o terceiro entregando o primeiro.

§1 Os três andares

O primeiro andar é **descritivo**: o que aconteceu. Ele olha para trás e organiza. Um relatório mensal, um gráfico de volume por produto, uma contagem de quebras por equipe — tudo isso é primeiro andar. É onde vive praticamente todo dashboard corporativo.

O segundo é **preditivo**: o que vai acontecer. Ele usa o passado para estimar algo que ainda não foi observado. A palavra "ainda" faz o trabalho pesado aqui: é isso que separa uma previsão de uma média histórica bem apresentada.

O terceiro é **prescritivo**: o que fazer a respeito. Ele transforma a estimativa em ação recomendada, o que exige saber não só o que vem, mas o que está na mão de quem lê.



Fig. 2.1 Cada degrau exige tudo do anterior mais uma coisa nova. Não dá pra pular: uma recomendação sem previsão por trás é palpite com cara de sistema.

§2 Por que quase todo projeto para no primeiro

Porque o primeiro andar é o único que não precisa estar certo sobre o futuro. Um relatório descritivo pode ser bonito, útil e completamente seguro: ele só repete o que já está no banco. Ninguém consegue provar que ele errou.

No segundo andar isso acaba. Você faz uma afirmação sobre algo que ainda não aconteceu, e o mundo depois confere. É desconfortável, e é por isso que muito projeto vendido como preditivo entrega, no fundo, uma média histórica com nome bonito.

NA VIDA REAL

Pense na sua conta bancária. O **extrato** mostra o que você gastou no mês passado: é descritivo. Ele é exato e nunca erra, porque só repete o que já aconteceu.

O **orçamento** do mês que vem é preditivo. Você usa o extrato para estimar quanto vai gastar em mercado, e no dia 30 dá para conferir se acertou. Ele pode estar errado — é esse o preço de dizer algo sobre o futuro.

E "**cancela a assinatura X e troque de plano de celular**" é prescritivo. Repare que essa frase precisa de duas coisas que o extrato não tem: uma previsão de quanto você vai gastar e o conhecimento do que está ao seu alcance mudar.

Um app que só mostra gráfico de gastos vive no primeiro andar, por mais bonito que seja.

ATENÇÃO · O TESTE QUE SEPARA OS DOIS

Se a saída do seu "modelo preditivo" não pode ser confrontada com o que aconteceu depois, ele é descritivo. Média dos últimos 12 meses apresentada como "projeção" é o caso clássico: não existe momento em que ela erra, porque ela nunca afirmou nada sobre o futuro.

O teste é simples: *existe uma data em que dá pra dizer que esse número estava errado?* Se não existe, é primeiro andar.

§3 O que muda em cada andar

ANDAR	PERGUNTA TÍPICA	O QUE VALIDA
Descritivo	Onde estão nossas quebras?	a própria base
Preditivo	Quantas quebras vamos ter em março?	o mês de março, quando chegar
Prescritivo	Em qual chamado eu mexo agora?	a quebra que não aconteceu

Repare na última linha. O andar prescritivo tem um problema de avaliação bem chato: quando ele funciona, o evento não acontece, e aí não sobra evidência. Provar valor no terceiro andar exige desenho de experimento, não só métrica de modelo. É um ponto que a banca pode cobrar e que vale ter na ponta da língua.

NO CRONOS · OS TRÊS ANDARES, NOMEADOS

- **Descritivo:** a análise exploratória inteira. 30 ativos concentram 61,7% das quebras; a equipe Team11 responde por 46% delas com 8% do volume. Isso já é acionável sem modelo nenhum — vira uma lista de vigilância.
- **Preditivo:** o Prophet (quantos incidentes amanhã) e a regressão logística (a chance deste chamado estourar). Os dois foram validados contra período que o modelo não viu.
- **Prescritivo:** o morning briefing e a fila ordenada por risco. É o andar mais frágil do projeto hoje, porque ainda não existe canal que entregue a recomendação onde o analista trabalha.

Vale assumir essa fragilidade em vez de esconder. Dizer "o terceiro andar está desenhado e não integrado" é mais forte do que deixar a banca descobrir que o alerta não chega em lugar nenhum.

COMO PEDIR

"Classifica essa entrega nos três andares: o que aqui é descritivo, o que é preditivo e o que é prescritivo. E pra cada coisa preditiva, me diz contra qual período ela foi validada."

REVISÃO RÁPIDA

- Descritivo olha para trás, preditivo afirma sobre o futuro, prescritivo recomenda ação.
- O segundo andar é desconfortável porque pode ser conferido depois. Por isso tanta gente fica no primeiro.
- Teste rápido: se não existe data em que o número possa ser declarado errado, é descritivo.
- O andar prescritivo tem problema de prova: quando funciona, o evento não acontece.
- No Cronos: AED é o primeiro, Prophet e logística são o segundo, briefing e fila de risco são o terceiro — e o terceiro ainda não está integrado.

CAPÍTULO III

A base e o recorte que define tudo

por que escolher as linhas é uma decisão de modelagem

Antes de qualquer técnica existe uma pergunta que decide o resultado inteiro: quais linhas entram na conta. No Cronos, duas maneiras razoáveis de filtrar a mesma base davam 25.600 e 107.416 registros. Uma delas estava errada, e o erro não era visível olhando o código.

§1 Anatomia de uma base

Uma tabela tem linhas e colunas, e isso todo mundo sabe. O que costuma passar batido são três perguntas sobre ela que mudam completamente o que dá pra fazer.

A primeira é a **granularidade**: o que é uma linha? Na base da Locaweb, uma linha é um incidente. Não é um dia, não é um cliente, não é um produto. Toda análise que você quiser fazer por dia exige agregar; toda análise por produto exige agrupar. Se você errar essa pergunta, todo o resto sai errado sem dar erro nenhum.

A segunda é o **tipo** de cada coluna: número, texto, data, categoria. Parece burocracia, mas define o que é possível. Data não é texto — se ela vier como texto, ordenar cronologicamente devolve 1º de janeiro, depois 1º de fevereiro, depois 1º de março, porque a ordenação é alfabética.

A terceira é a **cardinalidade**: quantos valores distintos aquela coluna tem. Prioridade tem cinco. Produto tem algumas dezenas. Item de configuração tem milhares. Colunas de cardinalidade muito alta se comportam de um jeito bem diferente na hora de virar entrada de modelo, e o capítulo XVI trata disso.

GLOSSÁRIO

Granularidade. O nível de detalhe de uma linha. Incidente, dia, mês, cliente. Mudar de granularidade sempre perde informação, nunca ganha.

Cardinalidade. Quantidade de valores distintos de uma coluna. Baixa: dia da semana (7). Alta: item de configuração (milhares).

População-alvo. O conjunto de linhas sobre o qual a sua pergunta se aplica. Quase nunca é a base inteira.

§2 O recorte não é limpeza, é modelagem

Existe uma ideia difundida de que filtrar dado é etapa de faxina: tira duplicata, tira linha vazia, segue a vida. Não é isso. Escolher quais linhas entram é definir sobre quem você está falando, e isso é uma afirmação sobre o mundo, não sobre o arquivo.

NA VIDA REAL

Pesquisa eleitoral. Duas empresas podem entrevistar o mesmo número de pessoas, com o mesmo questionário, e publicar resultados diferentes. A diferença mora quase sempre no recorte: entrevistou eleitor registrado ou adulto qualquer? Considerou quem disse que provavelmente não vota? Excluiu indeciso do cálculo do percentual ou deixou dentro?

Nenhuma dessas escolhas é erro de conta. Todas mudam o número final. E é por isso que instituto sério publica a metodologia junto do resultado — o recorte é parte do resultado.

§3 O caso do filtro de KPI

A Locaweb não mede o OLA sobre tudo que entra. Existe uma regra de elegibilidade, e ela tem três condições ao mesmo tempo: o incidente precisa ser de prioridade 1, 2 ou 3; não pode ser filho de outro incidente; e não pode ter fechado como "Sem Intervenção".

Na primeira tentativa, o filtro aplicado foi só a segunda condição — incidente sem pai. Parecia razoável: "quero os incidentes que existem por si só". O resultado foram 107.416 registros, 88% da base. E 88% é um número que não acende alarme nenhum, porque soa como "quase tudo conta, faz sentido".

O correto são **25.600 registros, 21% da base**. A diferença de 82 mil linhas não vinha de dado sujo: vinha de eu ter respondido uma pergunta diferente da que a Locaweb responde.




Fig. 3.1 As três condições aplicadas em sequência. A Locaweb já entrega o resultado pronto no campo Entrou para KPI?, que codifica as três de uma vez — usar o campo oficial evita reimplementar a regra e errar.

NO CRONOS · O RECORTE REDEFINIU O PROJETO

Fixar a população em 25.600 mudou o que o projeto é. O volume total da operação passou de 122 mil incidentes ao ano, mas a meta de OLA é medida sobre um quinto disso. Consequências diretas:

- A série que o Prophet prevê é a série elegível, não o volume total. São curvas com comportamento diferente.
- Das 25.600, apenas **248 violaram o OLA** — 0,97%. Esse número minúsculo é o que torna o capítulo XIX (evento raro) obrigatório.
- 65,6% do volume total fecha como "Sem Intervenção" e por isso nunca entra na conta. É volume que infla o gráfico e não mexe na meta.

Notebook 02, seção 4. O filtro está travado com assert para que qualquer alteração futura na base quebre o notebook em vez de mudar o número em silêncio.

ATENÇÃO · ONDE A INTUIÇÃO ERRA

O filtro errado não parecia errado. Ele rodava, não dava exceção, devolvia um número plausível e produzia gráficos bonitos. Erro de recorte é silencioso por natureza: ele não quebra nada, só responde outra pergunta.

A defesa não é revisar o código, é conferir o total contra uma fonte externa. Quando o campo oficial da Locaweb devolveu 21% e a minha regra devolveu 88%, ficou óbvio. Sem essa conferência, ficaria invisível até a banca perguntar.

COMO PEDIR

"Antes de rodar, me diz qual é a granularidade da linha e quantos registros sobram depois de cada filtro, um por um. E confere o total final contra alguma fonte oficial — se não tiver, me avisa que não tem."

REVISÃO RÁPIDA

- Três perguntas sobre qualquer base: granularidade (o que é uma linha), tipo das colunas, cardinalidade.
- Recortar não é limpar. Escolher as linhas é definir sobre quem você fala, e isso é modelagem.
- No Cronos: 122.543 na base, 25.600 elegíveis ao KPI (21%), 248 violações (0,97% dos elegíveis).
- O filtro incorreto devolvia 107.416 (88%) sem dar nenhum erro. Recorte errado é silencioso.
- Sempre que existir campo oficial que já codifica a regra, use o campo em vez de reimplementar.

II

PARTE SEGUNDA

Olhar antes de modelar

IV Para que serve a análise exploratória

V Distribuição, média e a tirania da cauda

VI Concentração e Pareto

VII Sazonalidade e efeito calendário

VIII Mudança de regime e anomalia

CAPÍTULO IV

Para que serve a análise exploratória

a fase que decide o projeto, e que todo mundo trata como enfeite

Análise exploratória tem fama de ser a parte chata: gerar uns gráficos, confirmar o óbvio e partir para o modelo. É o contrário. No Cronos, a AED matou um dos diferenciais do produto, trocou a variável-alvo e descobriu um evento que teria destruído a validação. Nenhuma dessas três coisas veio de modelo.

§1 O que a AED realmente é

Análise exploratória de dados, ou AED, é a etapa em que você olha para a base antes de decidir o que fazer com ela. A sigla em inglês é EDA, e o nome vem de um livro do John Tukey de 1977 que propôs uma ideia então incomum: olhar o dado sem hipótese pronta, para deixar ele sugerir a pergunta.

A confusão vem daí. Como a AED não testa hipótese e não prevê nada, ela parece preliminar. Mas as decisões que ela toma são as mais caras de reverter depois: qual é o alvo, qual é a população, qual período serve para treinar, quais colunas existem de verdade e quais estão vazias na prática.

Errar um modelo custa uma semana. Errar o alvo custa o projeto.

§2 As cinco coisas que se procura

Não existe roteiro oficial, mas na prática toda AED útil vai atrás das mesmas cinco coisas. Vale conhecer a lista porque ela também serve de pedido: se você me mandar "faz a AED", é isso que eu deveria devolver.




Fig. 4.1 As cinco buscas de uma AED. A quinta está destacada porque é a que quase ninguém faz e a que mais estraga modelo: uma base que mudou de regime no meio treina um modelo para um mundo que não existe mais.

NA VIDA REAL

Comprar um apartamento. Ninguém assina o contrato olhando só as fotos do anúncio: você visita, abre o armário, liga o chuveiro, vai num dia de chuva ver se tem infiltração e passa na rua num sábado à noite para ver o barulho.

Nada disso é "a compra". É a fase de descobrir o que você está comprando de verdade — e é justamente ela que decide se você segue ou desiste. A AED é a visita ao imóvel.

Modelar sem AED é comprar pelas fotos. Às vezes dá certo. Quando dá errado, você só descobre morando lá.

§3 O que a AED decide

Cada uma das cinco buscas termina em decisão, não em gráfico. A forma decide se você usa média ou mediana e se precisa transformar a variável. O buraco decide se a coluna entra no modelo. O extremo decide se você corta, mantém ou trata à parte. A relação decide quais colunas são redundantes. E a mudança decide qual período pode ser usado para treinar.

Se um gráfico da sua AED não terminou em nenhuma dessas decisões, ele era enfeite mesmo.

Vale reparar que as três decisões são anteriores a qualquer linha de modelagem, e que nenhuma delas apareceria depois. Um modelo treinado no volume total, com dado de 2024 junto, rodaria sem erro e entregaria número. Errado, mas entregaria.

NO CRONOS · TRÊS DECISÕES QUE VIERAM DA AED

- **Um diferencial do produto foi cancelado.** As Sprints 1 e 2 venderam um "detector de cascata": incidentes pequenos escalando até virar um grande. A AED mostrou que 87% das quebras de OLA são de incidentes isolados, e que a taxa de escalada é de 21% contra cerca de 60% que o acaso produziria. A hipótese não sobreviveu ao dado.
- **O alvo mudou.** Prever o volume total parecia natural, até a AED mostrar que o total salta de 3.996 para 21.561 incidentes entre agosto e setembro. A série elegível ao KPI, que é a que a meta usa, atravessou o mesmo mês sem se mexer: 2.330 para 2.324.
- **O período de treino ficou restrito a 2025.** A base tem registros de 2024, mas em volume ridículo — 6 incidentes em janeiro de 2024, 118 em dezembro. Não é histórico, é o sistema sendo implantado.

§4 Quando parar

AED não tem fim natural: sempre dá pra cruzar mais duas colunas. O critério prático é: pare quando os gráficos novos pararem de mudar decisão. Se você já sabe qual é o alvo, qual é o recorte, qual é o período e quais colunas servem, a AED cumpriu o papel. O resto é curiosidade, e curiosidade é ótima, mas não é entrega.

ATENÇÃO · O GRÁFICO QUE CONFIRMA O QUE VOCÊ JÁ ACHAVA

O risco da AED é procurar confirmação. Você suspeita que sexta é o pior dia, plota sexta, vê um número alto e fecha a questão. Só que "alto" comparado a quê, e com qual margem?

No Cronos isso apareceu de forma concreta: quinta-feira tem a maior média (48,4 incidentes/dia), mas a margem de erro é de $\pm 9,4$. Segunda tem 44,0 com $\pm 8,4$. As faixas se sobrepõem quase inteiras — não dá para afirmar que quinta é pior que segunda. O que o dado sustenta é a diferença entre dia útil e fim de semana, que é grande e não ambígua.

COMO PEDIR

"Faz a AED cobrindo as cinco frentes: forma de cada coluna, valores faltantes, extremos, relação entre colunas e mudança de comportamento ao longo do tempo. Para cada gráfico, escreve qual decisão ele muda. Se não mudar nenhuma, corta o gráfico."

REVISÃO RÁPIDA

- A AED decide alvo, população, período e colunas. São as decisões mais caras de reverter.
- Cinco buscas: forma, buraco, extremo, relação e mudança de regime.
- Gráfico que não termina em decisão é enfeite.
- No Cronos a AED cancelou a cascata, trocou o alvo para a série elegível e restringiu o treino a 2025.
- Pare quando gráfico novo parar de mudar decisão.

CAPÍTULO V

Distribuição, média e a tirania da cauda

por que a média quase sempre é o número errado


O tempo médio de resolução dos incidentes elegíveis do Cronos é de 221 horas. A mediana é de 1 hora e 12 minutos. Não é erro de conta: os dois números estão certos e descrevem a mesma base. Este capítulo explica como isso é possível e por que quase sempre é a mediana que você quer.

§1 Distribuição é o formato do dado

Distribuição é a resposta para "quantos casos existem em cada faixa de valor". Você conta quantos incidentes levaram menos de uma hora, quantos levaram de uma a duas, e assim por diante. O desenho dessas contagens é um histograma, e o formato dele diz mais sobre a base do que qualquer resumo numérico.

O formato que todo mundo aprende primeiro é o sino simétrico, a famosa curva normal: a maioria dos casos perto do meio, poucos nas pontas, e as duas pontas equilibradas. Altura de pessoas é assim. Nota de prova costuma ser assim.

Só que quase nada em operação é assim. Tempo de atendimento, valor de compra, tamanho de arquivo, duração de incidente: tudo isso tem chão em zero e não tem teto. Um incidente não pode durar menos que zero, mas pode durar três anos. Essa assimetria estrutural produz um formato completamente diferente.



Só 7,2% dos incidentes estão acima da média. A média não é o caso típico: é o efeito de 2.260 casos muito longos.

Fig. 5.1 Tempo entre abertura e resolução dos 25.042 incidentes elegíveis com data de resolução preenchida. A última barra é aberta: ela vai de 3 dias a 24.522 horas, quase três anos.

§2 Média, mediana e moda

Os três respondem "qual é o valor típico", e discordam sempre que a distribuição é torta.

A **média** soma tudo e divide pela quantidade. Ela usa todos os valores, o que parece bom, e é justamente esse o problema: um único caso absurdo puxa a média inteira. Um incidente que ficou aberto três anos entra na conta com o mesmo peso de três anos.

A **mediana** é o valor do meio quando você enfileira todos em ordem. Metade está abaixo, metade acima. Ela ignora *quanto* os extremos são extremos e só conta que eles estão de um lado. Por isso não se move quando aparece um caso monstruoso.

A **moda** é o valor mais frequente. Serve pouco em variável contínua e serve muito em categoria: a moda de "produto" é o produto que mais aparece.

NA VIDA REAL

Renda no Brasil é o exemplo clássico. Quando sai a notícia de que "a renda média do brasileiro é X", o X é sempre maior do que a renda de quase todo mundo, porque um punhado de rendas altíssimas puxa a média para cima.

É a mesma matemática do bar com dez clientes: entra o dono de uma empresa de bilhões e, na média, todo mundo ali virou milionário. A mediana não se mexeu um centavo, e é ela que descreve o cliente típico daquele bar.

§3 Percentil: a régua que não engana

Percentil generaliza a mediana. O percentil 90 é o valor abaixo do qual estão 90% dos casos. A mediana é simplesmente o percentil 50.

Percentil é a ferramenta certa para falar de operação, porque ele responde na linguagem de compromisso: "90% dos incidentes resolvem em até 40 horas" é uma frase verificável e útil. "A média é 221 horas" não é nem uma coisa nem outra.

MEDIDA	TEMPO ATÉ A RESOLUÇÃO
Mediana (p50)	1,2 ho caso típico
p75	4,0 htrês de cada quatro
p90	40,0 honde a cauda começa
p99	6.044 ho 1% que distorce tudo
Média	221,5 hnenhuma das anteriores

Repare no salto entre p75 e p90: de 4 horas para 40. É aí que a cauda começa. E entre p90 e p99, de 40 para 6.044. Um resumo com uma linha só nunca mostraria isso.

§4 O extremo é erro ou é informação?

A tentação diante de um valor absurdo é remover. Às vezes é o certo: um incidente com data de abertura em 1899 é erro de sistema. Mas o valor extremo costuma ser exatamente o caso que interessa.

No nosso caso, os 2.260 incidentes que passam de três dias não são erro. São incidentes elegíveis ao KPI que ficaram parados, e são justamente onde mora a violação de OLA. Removê-los para "limpar a distribuição" seria apagar o objeto de estudo.

NO CRONOS · O QUE ESSA DISTRIBUIÇÃO MUDOU

- **Todo relatório de tempo passou a usar mediana e percentil**, com a média aparecendo só quando o assunto é soma (custo total de horas, por exemplo, onde a média é a medida certa).
- **Duração ficou fora do modelo de risco**, mas por outro motivo, que é vazamento — o capítulo XVII trata disso. A distribuição só reforçou que ela seria uma entrada difícil de qualquer jeito.
- **O prazo de OLA foi inferido da distribuição**, não de documento: no P2 nenhum caso cumprido passa de 3,5h no percentil 99 e o menor violado tem 4,0h, o que coloca o prazo em torno de 4 horas.

COMO PEDIR

"Para qualquer variável de tempo ou valor, me dá mediana, p75, p90 e p99 junto com a média, e diz que percentual dos casos fica acima da média. Se esse percentual for muito diferente de 50%, usa mediana no texto."

REVISÃO RÁPIDA

- Distribuição é o formato do dado. Quase nada em operação tem formato de sino.
- Média usa todos os valores e por isso é sequestrada por extremos; mediana ignora o tamanho do extremo.
- No Cronos: média 221,5h contra mediana 1,2h, e só 7,2% dos casos estão acima da média.
- Percentil fala a língua da operação: "90% resolvem em até 40 horas".
- Extremo raramente é lixo. Aqui, o extremo é exatamente onde mora a violação de OLA.

CAPÍTULO VI

Concentração e Pareto


quando poucos itens explicam quase tudo — e por que isso é uma boa e uma má notícia

Trinta itens de configuração concentram 61,7% das quebras de OLA da Locaweb. Esse é o número mais acionável do projeto inteiro e, ao mesmo tempo, o mais perigoso: ele significa que uma planilha resolve boa parte do problema, e que qualquer modelo nosso precisa provar que ganha de uma planilha.

§1 A regra que não é regra

Vilfredo Pareto era um economista italiano que, por volta de 1896, notou que 80% da terra da Itália pertencia a 20% da população. Depois começaram a ver o mesmo padrão em todo lugar: vendas por cliente, defeitos por causa, tráfego por página.

Virou o "princípio 80/20", e virou também uma frase solta que as pessoas repetem sem medir. Os números reais quase nunca são 80 e 20. O que importa não é o par de números: é que a curva é *desigual*, e o quanto.



Eixo x: os 125 itens de configuração que registraram quebra, do que mais quebra para o que menos.
Eixo y: percentual acumulado das 248 quebras de OLA de 2025.

Fig. 6.1 Curva acumulada das 248 quebras de OLA de 2025 sobre os 125 ativos que registraram ao menos uma. Quanto mais a curva descola da diagonal, mais concentrado é o problema. Fonte: base elegível, coluna Item de configuração.

NA VIDA REAL

Olhe o seu celular. Você tem dezenas de aplicativos instalados e passa quase todo o tempo em três ou quatro. Olhe o armário: você tem muita roupa e usa sempre as mesmas peças. Olhe a sua playlist: são centenas de músicas e umas vinte tocam sempre.

Esse é o padrão, não a exceção. Sempre que existe uma escolha humana repetida ao longo do tempo, o uso se concentra. E onde há concentração há uma alavanca: mexer nos três apps que você mais usa muda a sua rotina; mexer nos quarenta que você nunca abre não muda nada.

§2 Como se lê uma curva dessas

A diagonal pontilhada é o mundo sem concentração: se todos os 125 ativos quebrassem na mesma frequência, 10 ativos dariam 8% das quebras, 50 dariam 40%, e assim por diante. Concentração é a distância entre a curva de verdade e essa diagonal.

Aqui, 10 ativos dão 45,2% em vez de 8%. A distância é enorme, e é isso que torna a lista acionável: não é preciso resolver a operação inteira para mexer no número.

NO CRONOS · A CONCENTRAÇÃO ESTÁ EM TODA PARTE

- **Ativos:** 30 de 125 concentram 61,7% das quebras. O campeão sozinho tem 32 das 248.
- **Equipes:** uma única equipe responde por 46% das quebras com 8% do volume.
- **Prioridade:** 206 das 248 quebras são P3 — que é justamente a prioridade mais baixa entre as elegíveis, e a de maior volume.
- **Reincidência:** metade das quebras do segundo semestre (55 de 111) aconteceu em ativos que já tinham quebrado no primeiro.

§3 A má notícia: concentração é uma régua difícil de bater

Aqui está o ponto que costuma passar despercebido e que a banca do challenge vai cobrar. Se 30 ativos explicam 62% das quebras, então uma regra de uma linha — "vigie estes 30 ativos" — já captura a maior parte do problema, sem modelo, sem treino e sem risco.

Isso significa que o modelo de risco não compete contra o acaso. Ele compete contra a planilha. E a planilha é grátis, é explicável e ninguém precisa validar.

ATENÇÃO · A RÉGUA TRIVIAL

Sempre que existir concentração forte, construa a regra ingênua correspondente e meça o quanto ela sozinha resolve. É a sua régua. No Cronos, "P3 mais a equipe crítica" já concentra muito, e o ganho do modelo precisa ser medido *acima* disso, não acima do zero.

Modelo que só empata com a planilha não é fracasso técnico — é informação. Ele diz que o problema é de gestão de ativo, não de previsão.

§4 Onde o modelo ainda ganha

A lista resolve a metade que tem histórico. A outra metade das quebras acontece em ativos que nunca quebraram antes, e para esses a planilha não tem nada a dizer.

Além disso, o P3 elegível tem cerca de 20 mil casos por ano, todos com a mesma prioridade. Dentro da fila de P3, a planilha não ordena nada: ela só marca alguns ativos. Ordenar 20 mil casos por probabilidade é o serviço que a intuição e a lista não fazem.

COMO PEDIR

"Mede a concentração com curva acumulada e me diz quantos itens explicam 50% e 80%. Depois monta a regra ingênua que essa concentração sugere, mede o desempenho dela sozinha, e usa isso como baseline do modelo."

REVISÃO RÁPIDA

- Pareto não é 80/20: é a constatação de que a curva é desigual. O número exato se mede.
- Leia a curva pela distância até a diagonal do "todos iguais".
- No Cronos: 30 ativos de 125 = 61,7% das quebras; 10 ativos = 45,2%.
- Concentração forte cria uma régua trivial. O modelo tem que ganhar dela, não do acaso.
- O modelo ganha onde a lista é cega: ativos sem histórico e ordenação dentro de uma fila grande e homogênea.

CAPÍTULO VII

Sazonalidade e efeito calendário

o que se repete, e o que só parece que se repete

A parte previsível do volume de incidentes é quase toda calendário: dia da semana e feriado. Descobrir isso foi ao mesmo tempo o principal resultado do modelo de previsão e o seu limite. Este capítulo trata de como se mede um ciclo e de como não confundir ciclo com coincidência.

§1 **Ciclo é o que volta**

Sazonalidade é qualquer padrão que se repete em intervalo conhecido. A palavra vem de "estação" e sugere ano, mas na prática os ciclos que mais importam são bem mais curtos.

Num negócio, três ciclos costumam existir ao mesmo tempo. O **semanal** é quase sempre o mais forte, porque ele é feito de gente: as pessoas trabalham de segunda a sexta. O **mensal** aparece onde existe fechamento, cobrança ou meta. E o **anual** aparece onde existe clima, férias escolares ou data comercial.

Um ciclo só é sazonalidade se o intervalo for conhecido de antemão. "Toda terça sobe" é sazonalidade. "A cada três ou quatro meses tem um pico" não é: é um padrão sem período fixo, e trata-se de outra coisa.




Fig. 7.1 Média diária de incidentes elegíveis por dia da semana, 2025. Domingo roda a metade de uma quinta. Entre segunda e quinta, a diferença cabe dentro da margem de erro.

§2 **O intervalo de confiança separa padrão de coincidência**

Quinta tem a maior média. Isso significa que quinta é o dia mais pesado? Não necessariamente, e o desenho mostra por quê.

Cada média foi calculada sobre algumas dezenas de quintas, e quintas diferentes têm volumes diferentes. O intervalo de confiança é a resposta para "se eu tivesse observado outro ano, quanto essa média poderia ter dado". Quando os intervalos de dois dias se sobrepõem quase inteiros, a diferença entre eles não se sustenta.

É o que acontece entre segunda ($44,0 \pm 8,4$) e quinta ($48,4 \pm 9,4$). Já entre quinta e domingo ($23,2 \pm 3,0$) não há sobreposição nenhuma. O padrão real aqui é *dia útil contra fim de semana*, não um ranking dos sete dias.

NA VIDA REAL

Pesquisa eleitoral outra vez: candidato com 32% e candidato com 30%, margem de erro de 2 pontos para mais ou para menos. As faixas são 30–34 e 28–32, e elas se cruzam. Dizer que um "está na frente" é ler ruído como notícia.

É exatamente o mesmo erro de dizer que quinta é pior que segunda.

§3 Feriado não é ciclo, é lista

Feriado se repete todo ano, mas não em intervalo fixo: Carnaval anda, Páscoa anda, e feriado que cai em fim de semana muda de efeito. Por isso feriado não entra como sazonalidade. Ele entra como *lista de datas*, uma coluna que vale 1 nos dias marcados e 0 nos outros.

O mesmo vale para recesso, promoção, campanha e janela de manutenção. Tudo isso é calendário conhecido de antemão, e calendário conhecido é informação de graça: você sabe hoje quais serão as datas do ano que vem.

NO CRONOS · O CALENDÁRIO VIROU COLUNA

- **Sazonalidade semanal ligada, anual desligada.** Com apenas um ano de histórico o modelo não tem como aprender um ciclo de doze meses: ele veria cada mês uma vez só e confundiria o mês com o acaso daquele mês.
- **Feriados brasileiros entram por lista automática,** com uma linha que pede o calendário do país inteiro. Não foram digitados à mão, o que evita esquecer feriado móvel.
- **O recesso de fim de ano ficou de fora, e cobrou caro.** Repare na diferença: o Natal e o Ano Novo *estão* na lista, porque são feriados de um dia. O recesso não é um dia, é uma janela de duas a três semanas em que a operação inteira desacelera. O último terço de dezembro cai 45% contra o mesmo terço de novembro — 305 contra 556 incidentes. A ferramenta aceita declarar uma janela em volta de uma data, e a gente não declarou.

Vale destacar esse último item porque ele é um erro nosso e é instrutivo: a informação estava disponível, era de graça, e a gente não usou. Não é limitação do método, é escolha que faltou.

COMO PEDIR

"Mede o ciclo semanal com intervalo de confiança e me diz quais dias realmente diferem entre si. E lista todo evento de calendário conhecido — feriado, recesso, fechamento, campanha — para entrar como coluna, em vez de virar erro do modelo depois."

REVISÃO RÁPIDA

- Sazonalidade é padrão de período conhecido. Sem período fixo, é outra coisa.
- Três ciclos típicos: semanal (o mais forte, feito de gente), mensal e anual.
- Sem intervalo de confiança, diferença entre médias é palpite. No Cronos, os cinco dias úteis são indistinguíveis entre si; o fim de semana não.
- Feriado e recesso entram como lista de datas, não como ciclo.
- Calendário conhecido é informação de graça. O recesso de dezembro estava disponível e ficou de fora — e virou erro do modelo.

CAPÍTULO VIII

Mudança de regime e anomalia

quando a base deixa de descrever o mesmo mundo

Em setembro de 2025 o volume mensal da Locaweb saltou de 3.996 para 21.561 incidentes. Nada aconteceu com a operação: mudou a instrumentação do monitoramento. Este é o tipo de evento que nenhum modelo prevê, que arruína validação em silêncio, e cuja solução quase nunca é limpar o dado.


§1 Três coisas diferentes com o mesmo apelido

A palavra "anomalia" é usada para três situações que exigem tratamentos opostos, e confundi-las é caro.

O **ponto fora da curva** é um caso isolado esquisito: um incidente com duração negativa, um valor mil vezes maior que os vizinhos. Ele afeta médias e pouco mais.

O **evento** é um período atípico com começo e fim: um apagão, uma campanha de Black Friday, uma pandemia. O mundo volta ao normal depois.

A **mudança de regime** é diferente das duas: a série passa a um novo patamar e fica lá. Não volta. O que mudou não foi o comportamento medido, foi frequentemente o jeito de medir.



A linha vermelha multiplica por cinco. A azul, que é a série da meta de OLA, atravessa setembro sem se mexer.

Fig. 8.1 Volume mensal de 2025: total da base (vermelho) contra o subconjunto elegível ao KPI (azul). O salto de setembro é mudança de instrumentação, não de operação.

NA VIDA REAL

Você usa um app que conta seus passos e a média era 6 mil por dia. Você troca de celular, e de repente a média vira 9 mil. Você não passou a andar mais: o sensor do aparelho novo é mais sensível e conta passos que o antigo ignorava.

Se alguém pegar essa série e concluir "ele ficou 50% mais ativo em março", a conclusão está errada, e nenhuma matemática mais sofisticada conserta. O que mudou foi o instrumento, não o fenômeno.

É exatamente o que aconteceu com o volume de incidentes da Locaweb em setembro. E é por isso que a primeira pergunta diante de um salto é sempre *mudou o mundo ou mudou o termômetro?*

§2 Por que nenhum modelo prevê isso

Modelo aprende regularidade do passado. Uma decisão administrativa — ligar monitoramento em mais servidores, mudar regra de classificação, integrar um sistema novo — não deixa rastro no passado, porque ela ainda não tinha acontecido.

Não é limitação da técnica escolhida. Prophet, ARIMA, rede neural, todos erram igual, porque a informação não está no dado. Este é um ponto importante para não cair na armadilha de trocar de algoritmo achando que o problema é o algoritmo.

ATENÇÃO · O ESTRAGO SILENCIOSO NA VALIDAÇÃO

Suponha que você treine com janeiro a agosto e teste com setembro a dezembro. O modelo vai errar feio, e você vai concluir que o método é ruim. Ou pior: vai trocar de método até achar um que "acerte", e esse será simplesmente o método que mais se ajusta ao acaso daquele trecho.

A mudança de regime precisa ser identificada *antes* de qualquer validação. Senão você não está medindo modelo, está medindo o azar de onde caiu o corte.

§3 As saídas possíveis

Diante de uma mudança de regime existem quatro caminhos, em ordem crescente de qualidade.

O primeiro é **ignorar**, que é o que acontece quando ninguém olhou. O segundo é **cortar** o período antigo e treinar só no novo, o que funciona mas joga histórico fora. O terceiro é **marcar** com uma coluna que indica antes e depois, deixando o modelo aprender os dois níveis. O quarto é **trocar de alvo**: encontrar uma medida que não tenha sido afetada pela mudança.

O quarto é o melhor quando é possível, porque ele não trata o problema — ele o dissolve.

Notebook 03, seção 4.10.2; notebook 01, seção 4.2.

NO CRONOS · A SAÍDA FOI TROCAR DE ALVO

O volume total multiplicou por cinco em setembro. A série elegível ao KPI passou de **2.330 para 2.324**, uma variação de 0,3%. Como a meta de OLA é medida sobre os elegíveis, prever a série elegível era ao mesmo tempo mais correto para o negócio e imune ao evento.

Isso é o que "olhar antes de modelar" entrega. A alternativa seria descobrir tudo isso depois, com um modelo treinado e um resultado inexplicável na mão.

Uma honestidade necessária: a imunidade foi comprovada no salto de setembro, e só nele. De outubro a dezembro a série elegível cai 39% (2.126, 1.634, 1.423) por causas que só estão parcialmente explicadas — recesso cobre parte de dezembro, e novembro segue sem causa verificada. Dizer "a série é imune a anomalias" seria generalizar demais.

COMO PEDIR

"Antes de definir treino e teste, plota a série mensal inteira e me diz se existe salto de patamar. Se existir, investiga se é operação ou instrumentação, e testa se alguma medida alternativa atravessa o evento sem mudar."

REVISÃO RÁPIDA

- Ponto fora da curva, evento e mudança de regime são três coisas com tratamentos diferentes.
- Mudança de regime não volta ao normal, e costuma ser mudança no jeito de medir.
- Nenhum algoritmo prevê decisão administrativa: a informação não existe no passado.
- Identifique a mudança antes de desenhar a validação, ou você mede azar em vez de modelo.
- Quatro saídas: ignorar, cortar, marcar, trocar de alvo. No Cronos foi a quarta — e a imunidade vale para setembro, não para o ano todo.

III

PARTE TERCEIRA

Prever o que vem

IX	O que é uma série temporal
X	Tendência, sazonalidade e resíduo
XI	O baseline: a régua que todo modelo tem que vencer
XII	Prophet por dentro
XIII	Erro e incerteza
XIV	Validação temporal

CAPÍTULO IX

O que é uma série temporal

quando a ordem das linhas é parte do dado

Em quase toda base, embaralhar as linhas não muda nada: cada incidente é um caso independente. Numa série temporal isso deixa de valer, e essa única diferença muda o modelo, a validação e o que significa errar. É a distinção mais importante da Parte III.

§1 A ordem é o dado

Série temporal é uma sequência de medições da mesma coisa ao longo do tempo, em intervalo regular. O volume diário de incidentes elegíveis é uma série: 365 números, um por dia de 2025, em ordem.

O que a torna especial não é ter uma coluna de data. É que *a posição de cada valor carrega informação*. O número de terça depende do de segunda. Se você embaralhar, os 365 números continuam lá, a média continua a mesma, o histograma fica idêntico — e a informação principal sumiu.



Ilustração esquemática do conceito; não são os valores da base.

Fig. 9.1 A mesma amostra, em ordem e embaralhada. Todos os resumos numéricos usuais dão exatamente o mesmo resultado nos dois casos, e só um deles tem sinal previsível.

§2 Autocorrelação: a série lembra de si mesma

Autocorrelação é a correlação de uma série com ela mesma deslocada no tempo. "Deslocada em 1" pergunta se o valor de hoje se parece com o de ontem. "Deslocada em 7" pergunta se o valor de hoje se parece com o do mesmo dia da semana passada.

É esse deslocamento — chamado de *lag*, ou defasagem — que dá nome a boa parte do vocabulário de séries. Uma autocorrelação alta no lag 7 é a assinatura numérica de um ciclo semanal.

E é também a razão de existir toda a Parte III. Se não houvesse autocorrelação nenhuma, a melhor previsão possível seria a média histórica, e não haveria o que modelar.

GLOSSÁRIO

Lag (defasagem). Deslocamento no tempo. "Lag 7" é o valor de sete períodos atrás.

Autocorrelação. O quanto a série se parece com uma versão atrasada de si mesma. Alta no lag 7 significa ciclo semanal.

Horizonte. Quantos períodos à frente você prevê. Quanto maior, pior o erro — sempre.

§3 Por que não dá para embaralhar na validação

Em problemas comuns, a validação sorteia 80% das linhas para treinar e 20% para testar. Em série temporal isso é proibido, e o motivo é constrangedor quando se vê: o sorteio coloca dias futuros no treino e dias passados no teste.

O modelo então "prevê" a terça-feira tendo visto a quarta-feira seguinte. O resultado fica ótimo e é uma fraude involuntária: em produção nunca vai existir o dia de amanhã na hora de prever amanhã.

A validação correta corta por data: treina no que veio antes, testa no que veio depois. Isso é o que o capítulo XIV desenvolve.

NA VIDA REAL

Toda estratégia de investimento testada no passado sofre desse mesmo risco, com o nome de *look-ahead bias*. Se o teste usa a cotação de fechamento para decidir uma compra que aconteceria durante o pregão, o resultado fica espetacular no papel e some no dinheiro real.

A regra é a mesma nos dois casos: no instante da decisão, só existe o que já foi observado.

§4 Frequência e agregação

A escolha do intervalo — hora, dia, semana, mês — não é detalhe. Ela decide o que é possível enxergar.

Agregar por semana elimina o ciclo semanal por construção: ele deixa de existir na série. Agregar por hora traz de volta o ciclo do expediente, mas multiplica o ruído, porque cada ponto passa a ter muito menos casos dentro.

Vale a regra prática: escolha a frequência da *decisão*, não a do dado. Se a decisão é escalar plantão por dia, a série é diária.

NO CRONOS · AS ESCOLHAS DE SÉRIE

- **Frequência diária**, porque a decisão de operação é diária. O dado permitiria por hora, e existe até uma coluna hora criada na base — que, é honesto dizer, nunca foi usada em nenhuma análise comitada.
- **Duas séries separadas, P2 e P3**, e não uma só. São volumes muito diferentes (cerca de 14 e 55 por dia) e metas diferentes. Somar as duas esconderia o P2, que é justamente a prioridade sob pressão.
- **365 pontos por série**. É pouco. É o suficiente para aprender o ciclo semanal, que aparece 52 vezes, e insuficiente para o ciclo anual, que aparece uma vez só. Essa contagem simples é o que decidiu a configuração do modelo no capítulo XII.

COMO PEDIR

"Trata isso como série temporal: nada de divisão aleatória entre treino e teste, o corte é por data. E antes de escolher a frequência, me diz de quantos pontos eu disponho e quantas vezes cada ciclo que eu quero capturar aparece nesse histórico."

REVISÃO RÁPIDA

- Série temporal é medição regular no tempo em que a ordem carrega informação.
- Embaralhar preserva todos os resumos estatísticos e destrói o sinal.
- Autocorrelação mede a semelhança da série com uma versão atrasada dela; alta no lag 7 é ciclo semanal.
- Validação aleatória coloca o futuro no treino. O corte tem que ser por data.
- Escolha a frequência da decisão. No Cronos: diária, duas séries (P2 e P3), 365 pontos cada.

CAPÍTULO X

Tendência, sazonalidade e resíduo

a conta de três parcelas que está por trás de quase todo modelo de série

Praticamente todo método de previsão de série, do mais simples ao mais moderno, faz a mesma coisa: separa a série em partes previsíveis e chama o que sobra de resíduo. Entender essa separação é entender o que o Prophet faz — e, mais importante, entender por que existe um teto de acerto que nenhum algoritmo ultrapassa.

§1 A série é uma soma

A decomposição clássica diz que o valor observado em cada dia é a soma de três coisas:

- **Tendência** — para onde o nível geral está indo, ignorando os solavancos. Cresce, cai ou fica parado.
- **Sazonalidade** — o que se repete em período conhecido. Aqui, o ciclo semanal.
- **Resíduo** — tudo o que sobra depois de tirar as duas primeiras.

Lendo a fórmula em voz alta: *o que aconteceu no dia é igual ao nível daquele período, mais o efeito daquele dia da semana, mais uma sobra.* Só isso.




Fig. 10.1 A mesma série lida como soma de três parcelas. O trabalho de modelagem é empurrar o máximo possível de informação para as duas parcelas de cima, esvaziando a de baixo.

NA VIDA REAL

Sua conta de luz do ano inteiro. Ela tem um **nível**: o consumo da geladeira, do chuveiro e das lâmpadas, que é mais ou menos o mesmo todo mês. Tem um **ciclo**: janeiro e fevereiro sobem porque o ar-condicionado liga, julho desce. E tem uma **sobra**: o mês em que a família veio passar duas semanas.

Quando alguém olha a conta e diz "esse mês veio cara", o que essa pessoa está fazendo é justamente separar as três parcelas de cabeça — ela desconta o nível, desconta o verão, e olha o que sobrou.

Um modelo de série faz isso com número em vez de intuição. A parte interessante é sempre a sobra: é ela que indica que algo fora do padrão aconteceu.

§2 Aditivo ou multiplicativo

A soma acima é a versão **aditiva**: o fim de semana tira um número fixo de incidentes, digamos 20, seja qual for o nível da série.

Existe a versão **multiplicativa**, em que o efeito é proporcional: o fim de semana tira 40% do movimento, e quando o nível dobra, a queda em unidades também dobra.

Como escolher: olhe se a amplitude do ciclo cresce junto com o nível. Se as ondas ficam maiores quando a série sobe, é multiplicativo. Se o tamanho das ondas é sempre o mesmo, é aditivo. No caso do Cronos, com a série da meta plana ao longo do ano, a distinção pouco importa e a versão aditiva serve.

§3 O resíduo é o número mais informativo do modelo

A tentação é olhar só para a parte que o modelo acertou. O resíduo é mais útil, porque ele diz o que ainda está faltando.

Se o resíduo tem padrão — sobe sempre no fim do mês, ou fica sistematicamente positivo por três meses seguidos — então existe sinal que o modelo não capturou, e há trabalho a fazer. Se o resíduo parece ruído sem estrutura, o modelo extraiu o que aquele conjunto de informação permitia.

ATENÇÃO · UMA FRASE QUE A GENTE TEVE QUE CORRIGIR

O material do projeto afirmava que o resíduo era "ruído irreduzível". A afirmação é forte demais, e a crítica que a derrubou é boa: os três métodos que convergiram para o mesmo erro usam *o mesmo conjunto de informação* — dia da semana, feriado e defasagens.

Três métodos concordando sobre a mesma informação demonstram o teto *daquela informação*, não o teto do dado. A formulação correta é "teto do sinal de calendário". Se entrasse uma informação nova — backlog aberto, mix de origem, virada de mês — o teto poderia mudar.

É uma correção de vocabulário que muda o que a frase promete. Vale internalizar: *irreduzível* é uma palavra que exige prova que a gente não tinha.

NO CRONOS · QUANTO VALE CADA PARCELA

Na série P3, quase toda a parte previsível é sazonalidade semanal. A tendência é praticamente plana ao longo de 2025, e o resíduo é grande: o erro médio do melhor modelo fica em torno de 11 a 12 incidentes por dia, numa série que roda a 55.

Isso significa que a decomposição extraiu o ciclo da semana e pouco mais. Não é falha de execução — é o diagnóstico de que, com as colunas disponíveis, o volume diário é em boa parte imprevisível. E foi esse diagnóstico que redirecionou o projeto para o modelo de risco por incidente, que responde outra pergunta.

Notebook 03, seções 4.5 (componentes do modelo) e 4.7 (rolling backtest).

COMO PEDIR

"Decompõe a série em tendência, sazonalidade e resíduo, e me mostra o gráfico do resíduo. Se ele tiver padrão sobrando, me diz qual informação disponível poderia explicar esse padrão antes de a gente trocar de algoritmo."

REVISÃO RÁPIDA

- Observado = tendência + sazonalidade + resíduo. Quase todo método de série faz essa separação.
- Aditivo: efeito em unidades fixas. Multiplicativo: efeito em porcentagem. Escolha olhando se a amplitude do ciclo cresce com o nível.
- O resíduo é o diagnóstico: padrão sobrando significa sinal não capturado.
- "Ruído irreduzível" exige prova que raramente se tem. O correto costuma ser "teto daquela informação".
- No Cronos, a parcela previsível é quase só o ciclo semanal — e foi isso que motivou o segundo modelo.

CAPÍTULO XI

O baseline: a régua que todo modelo tem que vencer

o palpite mais burro que ainda faz sentido

Um erro de 11,8 incidentes por dia é bom ou ruim? A pergunta não tem resposta sozinha. Ela só ganha sentido comparada com o que se conseguiria sem modelo nenhum. Esse comparador tem nome, é obrigatório, e no nosso caso ele quase venceu o modelo.

§1 Por que o número sozinho não diz nada

Suponha que eu chegue dizendo que o modelo erra 11,8 por dia. Você não tem como julgar. Erra pouco? Erra muito? Se o volume médio fosse 12 por dia, o modelo seria inútil. Se fosse 500, seria excelente.

Mas mesmo sabendo que o volume médio é 55, ainda falta a informação principal: *quanto erraria alguém sem modelo?* É essa a pergunta que o baseline responde.

Baseline é o palpite mais burro que ainda faz sentido, calculado sobre exatamente o mesmo período de teste. Ele não é um detalhe metodológico: sem ele, nenhum número de erro significa coisa alguma.


§2 As três réguas de qualquer série diária

Três baselines cobrem quase todo caso, e os três cabem em uma linha de código cada.

O **ingênuo** diz que amanhã vai ser igual a hoje. Parece bobo e é surpreendentemente difícil de bater em séries que mudam devagar.

A **média móvel de 7 dias** diz que amanhã vai ser a média da última semana. Ela suaviza o ruído do dia a dia, e por isso costuma ganhar do ingênuo quando a série oscila muito.

O **sazonal ingênuo** — ou sazonal-7 — diz que a próxima terça vai ser igual à terça passada. Repare que essa terceira régua já embute uma teoria sobre o mundo: a de que o dia da semana manda no número. Quando ela ganha das outras duas, você descobriu a sazonalidade semanal sem treinar modelo nenhum.



O ingênuo e a média-7 achatam a semana numa reta. O sazonal-7 copia o formato da semana anterior, e por isso é a régua difícil de bater em qualquer série feita de rotina humana.

Fig. 11.1 As três réguas projetadas a partir do mesmo ponto. Ilustração esquemática do mecanismo; os erros medidos na série real estão na tabela do §4.

NA VIDA REAL

A previsão do tempo enfrenta o mesmo juiz, e lá o baseline tem nome próprio: *persistência* — amanhã vai fazer o tempo de hoje. Dependendo da região e da época, a persistência acerta a maior parte dos dias.

Um meteorologista que acertasse pouco acima disso não seria bom, estaria empatando com um palpite que custa zero. É por isso que serviço meteorológico sério publica o ganho sobre a persistência, e não o acerto bruto. O acerto bruto sozinho é propaganda.

§3 Cada série tem o seu melhor baseline

Este é o detalhe que mais dá problema na hora de defender um resultado. Não existe "o baseline" no singular. Você calcula os três e o melhor deles é a régua daquela série.

Comparar sempre contra o mesmo baseline, escolhido de antemão, é o jeito mais fácil de inflar um resultado sem mentir em nenhum número isolado.

ATENÇÃO · O ERRO QUE A GENTE COMETEU E TEVE QUE CORRIGIR

O material do projeto anunciou por um tempo um ganho de **26%** do modelo sobre o baseline na série P2. O número estava certo — contra o sazonal-7. Só que o próprio notebook já mostrava que, no P2, o melhor baseline é a média-7, não o sazonal-7.

Contra o baseline correto, o ganho é de **15%**: 4,17 contra 4,91. Nenhum número foi inventado, e mesmo assim a comparação estava viciada. Corrigir isso foi o conserto mais barato e de maior retorno defensivo do projeto.

§4 Os números do Cronos

MÉTODO	P2 · ERRO/DIA	P3 · ERRO/DIA
Prophet	4,17	11,76
Média móvel de 7 dias	4,91	—
Sazonal ingênuo (7 dias)	5,67	11,25
Melhor baseline	4,91	11,25

Erro médio absoluto no rolling backtest, notebook 03, seção 4.7.

NO CRONOS · O BASELINE GANHOU EM UMA DAS DUAS SÉRIES

No P2 o Prophet vence por 15%. No P3 ele **perde**: 11,76 contra 11,25 do sazonal-7.

A tentação é esconder ou chamar de empate. A leitura honesta é melhor de defender e mais interessante: se um modelo treinado empata com "repetir a semana passada", isso quer dizer que *o previsível naquela série é só calendário*. Não há sinal escondido esperando um algoritmo mais esperto.

Esse diagnóstico economizou uma sprint inteira. Sem ele, o caminho natural seria tentar rede neural, depois modelo híbrido, depois mais features — tudo para disputar a terceira casa decimal de um teto que já estava demonstrado.

COMO PEDIR

"Antes de treinar qualquer modelo, roda os três baselines — ingênuo, média-7 e sazonal-7 — no mesmo corte de validação e me devolve a tabela de erro. Depois compara o modelo contra o melhor baseline de cada série, nunca contra um fixo. Se o modelo não ganhar, quero saber."

REVISÃO RÁPIDA

- Erro sem baseline não é informação. O baseline é o piso obrigatório de comparação.
- Três réguas para série diária: ingênuo, média-7 e sazonal-7.
- O sazonal-7 embute a teoria de que o dia da semana manda; quando ele ganha, você achou sazonalidade sem modelar.
- Cada série tem o seu melhor baseline. Comparar sempre com o mesmo infla resultado sem mentir em número nenhum — foi o que produziu o "26%" que virou 15%.
- No Cronos o Prophet ganha 15% no P2 e perde por pouco no P3. Modelo que empata com o baseline é diagnóstico, não fracasso.

CAPÍTULO XII

Prophet por dentro

o que a ferramenta faz, e o que ela não faz

Prophet é uma biblioteca de previsão de séries criada no Facebook em 2017. Ela ficou popular por um motivo específico: em vez de exigir que você entenda de estatística de séries, ela pede que você descreva o calendário do seu negócio. Este capítulo abre a caixa.

§1 Um modelo de curva, não de memória

A família clássica de modelos de série — ARIMA e parentes — trabalha com memória: o valor de hoje é explicado pelos valores dos dias anteriores e pelos erros dos dias anteriores.



O Prophet faz outra coisa. Ele trata a previsão como um problema de *ajuste de curva no tempo*. A data não é só a posição na fila: é a variável explicativa. O modelo monta uma função do tempo e ajusta os parâmetros dela para passar perto dos pontos observados.

Essa escolha tem uma consequência prática grande: como a data é a entrada, o Prophet consegue prever qualquer data futura diretamente, sem precisar simular dia a dia até chegar lá. E lidar com buraco na série — dias sem observação — deixa de ser problema.

§2 A soma que ele monta

O Prophet escreve a série exatamente como a decomposição do capítulo X, com uma parcela a mais:

- **Tendência** — uma reta que pode mudar de inclinação em pontos ao longo do tempo.
- **Sazonalidade** — ondas ajustadas por combinação de senos e cossenos, o que permite formatos de ciclo bem irregulares.
- **Feriados** — uma lista de datas com efeito próprio, cada uma podendo empurrar a série para cima ou para baixo.
- **Resíduo** — o que sobra.

1 · TENDÊNCIA — reta que dobra em pontos de mudança**2 · SAZONALIDADE — ondas de período fixo****3 · FERIADOS — lista de datas, cada uma com efeito próprio**

A previsão é a soma das três linhas. Cada peça é estimada de uma vez só, sobre o histórico inteiro.

Fig. 12.1 As peças que o Prophet monta. A tendência é uma reta que pode dobrar; a sazonalidade é uma onda de período fixo; feriados são datas isoladas com efeito próprio.

§3 As três decisões que realmente importam

O Prophet tem dezenas de parâmetros e você precisa mexer em três.

A primeira é **quais sazonalidades ligar**. E a regra para decidir não é estatística, é aritmética: conte quantas vezes o ciclo aparece no seu histórico. O ciclo semanal aparece 52 vezes em um ano — dá para aprender. O ciclo anual aparece uma vez — não dá. Ligar sazonalidade anual com um ano de dado faz o modelo decorar os acasos daquele ano específico e chamar isso de padrão.

A segunda é **o calendário de feriados**. O Prophet aceita o calendário de um país inteiro por nome, e aceita eventos customizados que você define.

A terceira é **a flexibilidade da tendência**: o quanto a reta pode dobrar. É aqui que mora o risco de o modelo decorar o passado em vez de aprender o padrão.

NO CRONOS · A CONFIGURAÇÃO E POR QUÊ

- **Sazonalidade semanal ligada, anual desligada.** 365 pontos: o ciclo da semana aparece 52 vezes, o do ano aparece uma.
- **Feriados brasileiros por lista automática,** o que evita esquecer feriado móvel.
- **Flexibilidade da tendência no padrão da biblioteca,** sem ajuste. Testamos aumentar: o erro no treino melhora de 10,23 para 9,50 e o erro no teste piora de 19,96 para **26,13**. Melhorar no que já se conhece e piorar no que não se conhece é a definição de decorar.
- **A mesma configuração para P2 e P3,** sem ajuste por série, para que a comparação entre as duas seja limpa.

§4 A configuração depende do horizonte

Uma descoberta que só apareceu quando fomos montar a projeção anual: a melhor configuração para prever os próximos 7 dias não é a melhor para prever os próximos 5 meses.

Para horizonte curto, deixar a tendência livre ajuda: ela acompanha o nível recente. Para horizonte longo, ela atrapalha, porque projeta a inclinação atual até o fim do ano e o erro se acumula.

CONFIGURAÇÃO DA TENDÊNCIA	ERRO EM 7 DIAS (P2)	ERRO NO ANO (P2)
Livre	3,80	4,94%
Travada (sem tendência)	3,98	1,66%

Notebook 06, seção 4.4.1. Erro de 7 dias em incidentes/dia; erro do ano em percentual do total projetado.

A lição vale além do Prophet: *o modelo é escolhido para um horizonte.* Perguntar "qual é o melhor modelo" sem dizer para quando é uma pergunta incompleta.

ATENÇÃO · O QUE O PROPHET NÃO FAZ

Ele não prevê mudança de regime, não descobre feriado sozinho, não modela relação com outras variáveis a menos que você as forneça explicitamente, e não garante que a banda de incerteza esteja calibrada — o capítulo XIII mostra o nosso caso em que ela não estava.

E ele não é determinístico: o ajuste parte de uma inicialização aleatória, então rodar duas vezes dá resultados levemente diferentes. Por isso a cobertura da banda no projeto é reportada em faixa, e não como valor exato.

COMO PEDIR

"Conta quantas vezes cada ciclo aparece no histórico antes de ligar sazonalidade. Usa a configuração padrão da biblioteca e só mexe se eu tiver um motivo escrito. E me diz para qual horizonte a configuração foi escolhida."

REVISÃO RÁPIDA

- Prophet ajusta uma curva em função da data, em vez de usar memória dos valores anteriores.
- Ele soma tendência (reta que dobra), sazonalidade (ondas) e feriados (lista de datas).
- Ligue uma sazonalidade só se o ciclo aparecer muitas vezes no histórico. 52 vezes sim, uma vez não.
- Mais flexibilidade melhorou o treino (10,23 → 9,50) e piorou o teste (19,96 → 26,13). Isso é decorar.
- A configuração depende do horizonte: tendência livre ganha em 7 dias e perde no ano.

CAPÍTULO XIII

Erro e incerteza

duas coisas diferentes que o mesmo gráfico costuma misturar

Dizer que o modelo erra 4 por dia e dizer que a previsão está entre 10 e 18 são afirmações de naturezas distintas. A primeira é um resumo do passado; a segunda é uma promessa sobre o futuro, e promessa se confere. No Cronos, uma dessas promessas não estava sendo cumprida.

§1 As três formas de resumir erro

Você previu 50 e aconteceram 62. O erro daquele dia foi 12. Para resumir centenas de dias num número só, existem três caminhos usuais, e eles respondem perguntas diferentes.

O **MAE**, erro médio absoluto, é a média dos erros ignorando o sinal.

Lendo em voz alta: *some o tamanho de cada erro e divida pela quantidade de dias*. É o mais fácil de explicar, porque sai na mesma unidade do dado: 11,8 significa 11,8 incidentes.

O **RMSE** eleva cada erro ao quadrado antes de somar. O efeito prático é que erros grandes pesam desproporcionalmente. Use quando um erro enorme é muito pior que vários erros pequenos.

O **MAPE** mede o erro em porcentagem do valor real. Ele permite comparar séries de tamanhos diferentes, e tem uma armadilha séria: quando o valor real é pequeno, a porcentagem explode. Num domingo com 5 incidentes, errar 5 vira 100%.

§2 O erro que os três escondem: o viés

Os três são cegos para o sinal do erro. Um modelo que erra 10 para cima em metade dos dias e 10 para baixo na outra metade tem o mesmo MAE de um modelo que erra 10 para cima *todos* os dias.

Para muitas decisões, o segundo é muito pior. E existe um caso em que ele é catastrófico: quando a decisão soma os dias.

NA VIDA REAL

Uma balança que ora marca 200 gramas a mais, ora 200 a menos, é uma balança ruidosa. Você pesa três vezes, tira a média, e chega perto do peso certo.

Uma balança que marca sempre 200 gramas a mais é uma balança *viciada*. Pesar dez vezes não ajuda — você vai errar 200 gramas com muita confiança. E se você estiver pesando dez ingredientes para somar numa receita, o erro final é de 2 quilos.


Erro aleatório se cancela na soma. Viés se acumula. É por isso que projeção de meta anual, que é uma soma de dias, exige medir o viés e não só o MAE.

§3 Incerteza é outra coisa

MAE, RMSE e MAPE olham para trás: são notas de prova já corrigida. Nenhum deles diz o que esperar amanhã.

Quem faz isso é o **intervalo de predição**: em vez de um número, o modelo devolve uma faixa, com um grau de confiança declarado. "A banda de 80%" é a promessa de que, em 80% dos dias, o valor real cai dentro dela.

E é uma promessa verificável. Basta contar. Se a banda de 80% contém o valor real em 80% dos dias do teste, ela está calibrada. Se contém em 60%, ela está mentindo — está dizendo que sabe mais do que sabe.

P2 · banda de 80% cobre entre 86% e 88% dos dias

Quando os pontos caem dentro da faixa na proporção prometida, a banda está calibrada.

P3 · a mesma banda de 80% cobre só 59% a 61%

a partir daqui o real cai fora da banda, dia após dia

Fig. 13.1 A mesma configuração de modelo produz uma banda honesta no P2 e uma banda otimista no P3. No P3 a queda de nível de novembro e dezembro está fora do que o treino permitia antecipar, e a banda não a comporta.

NO CRONOS · A BANDA CUMPRE NO P2 E NÃO CUMPRE NO P3

Medimos a cobertura empírica nos 92 dias de teste:

- **P2: entre 86% e 88%** contra os 80% prometidos. Calibrada, e até conservadora.
- **P3: entre 59% e 61%** contra 80%. Subestima a incerteza.

Reportamos faixa em vez de valor único porque o ajuste do Prophet não é determinístico e a cobertura oscila cerca de um ponto entre execuções.

Publicar "60,9%" daria aparência de precisão que a medição não tem.

A consequência prática é direta: no P2 dá para dimensionar operação pelo topo da banda; no P3 não dá, e a frase "pior caso" precisou sair do material onde se referia ao P3.

Notebook 03, seção 4.10.1.

ATENÇÃO · "±" NÃO É INTERVALO

Escrever " $\pm 4/\text{dia}$ " ao lado de um MAE é um erro comum e a gente cometeu. O símbolo sugere um intervalo com cobertura associada, e MAE não tem cobertura nenhuma: é a média dos erros passados.

A correção adotada foi escrever "erro médio (MAE)" para o resumo do passado e "banda de 80%" para a faixa, sempre publicando a cobertura medida ao lado. Duas coisas diferentes, dois nomes diferentes.

COMO PEDIR

"Reporta MAE e também o erro médio com sinal, para eu ver se existe viés. E se o modelo devolver banda, mede a cobertura empírica dela no teste e publica esse número junto — banda sem cobertura medida é promessa não verificada."

REVISÃO RÁPIDA

- MAE é a média do tamanho dos erros; RMSE pune erro grande; MAPE compara séries de tamanhos diferentes e explode em valores pequenos.
- Os três são cegos ao sinal. Erro aleatório se cancela na soma; viés se acumula.
- Erro resume o passado. Intervalo de predição é promessa sobre o futuro, e se confere contando.
- No Cronos: banda de 80% cobre 86–88% no P2 (honesta) e 59–61% no P3 (otimista).
- " $\pm$ " ao lado de MAE é errado: MAE não tem cobertura associada.

CAPÍTULO XIV

Validação temporal

como saber se o modelo funciona antes de apostar nele

Validar é simular o uso real antes de usar. Em série temporal isso tem uma regra inegociável — nada do futuro pode estar no treino — e um protocolo que reproduz a rotina de verdade: treinar de novo, prever de novo, muitas vezes. É o capítulo que mais separa um resultado defensável de um resultado bonito.

§1 A regra inegociável

No instante da previsão, o modelo só pode ter visto o que já aconteceu. Parece óbvio escrito assim, e é violado o tempo todo, quase sempre sem má intenção: basta usar a divisão aleatória entre treino e teste que vem por padrão em toda biblioteca.

O sorteio embaralha as datas. Metade das quartas-feiras de novembro vai para o treino, e o modelo então "prevê" uma terça de outubro sabendo o que aconteceu depois dela. O número fica ótimo, e não significa nada.

§2 Corte por data, o protocolo mínimo

A versão mais simples da validação correta é escolher uma data, treinar com tudo que veio antes e testar com tudo que veio depois. Chama-se corte fora do tempo, ou *out-of-time*.

É simples e tem duas fraquezas. A primeira é que o resultado depende de onde você cortou: se o período de teste for atípico, o modelo parece pior do que é. A segunda é que ele mede um treino único, e na prática o modelo será retreinado toda semana.

§3 Rolling backtest: simular a rotina

O protocolo que resolve as duas fraquezas repete o corte muitas vezes, deslizando a data para frente. Cada repetição imita literalmente um dia de uso: treina com tudo até ali, prevê os próximos dias, guarda o erro, e a data anda.

O número que sai daí é o erro que se deve publicar, porque é o único que reproduz a rotina. No projeto, é dele que vêm os 4,17 do P2 e os 11,76 do P3.




Fig. 14.1 O rolling backtest do Cronos. Cada barra é um retreino completo do modelo, com a data de origem andando quatro dias por vez. Nenhuma rodada enxerga o que está à direita da sua barra dourada.

ATENÇÃO · O MESMO MODELO TEM VÁRIOS ERROS

O material do projeto chegou a exibir quatro números de erro diferentes para o mesmo modelo, e todos estavam certos — eram protocolos diferentes. O corte único de jan–set prevendo 92 dias dá **19,96** no P3; o rolling dá **11,76**.

A diferença não é erro de conta: o corte único carrega inteira a queda de novembro e dezembro, enquanto o rolling reabsorve o novo patamar a cada retreino. Toda vez que um erro aparecer em slide ou relatório, o protocolo tem que estar escrito ao lado do número.

§4 O mesmo princípio fora de séries

A regra vale para qualquer modelo que vá rodar no futuro, mesmo quando o dado não parece uma série. O modelo de risco de OLA classifica incidentes, um a um, e ainda assim foi validado por data: treino com os 20.417 incidentes até 30 de setembro, teste com os 5.183 do último trimestre.

Testamos as duas formas de separar, no mesmo modelo, para medir a diferença.

SEPARAÇÃO	ROC AUC	PR-AUC	QUEBRAS NO TOP 50
Temporal (adotada)	0,869	0,296	15
Aleatória	0,826	0,153	10

Notebook 04, seção 4.10.4.

NO CRONOS · A DISTORÇÃO NÃO TEM DIREÇÃO PREVISÍVEL

O senso comum diz que a divisão aleatória sempre infla o resultado, porque vaza futuro para dentro do treino. No nosso caso ela produziu números *piores*, não melhores.

O motivo é que ela também muda a composição do teste: ao sortear, o teste passa a conter incidentes de todo o ano, inclusive perfis raros do começo do período, e o problema fica diferente.

A conclusão prática importa mais que a direção: a divisão aleatória não responde uma versão otimista da pergunta certa, ela responde *outra pergunta*. E por isso não existe fator de correção que conserte — só refazer com o corte por data.

COMO PEDIR

"Valida por data, nunca por sorteio, mesmo que o modelo não seja de série temporal. Faz rolling backtest com várias origens e me diz quantas origens e qual horizonte. E rotula todo número de erro com o protocolo que o produziu."

REVISÃO RÁPIDA

- Regra inegociável: no instante da previsão, só existe o passado.
- Corte out-of-time é o mínimo; ele depende de onde você cortou e mede um treino único.
- Rolling backtest desliza a origem e retreina a cada rodada, reproduzindo a rotina. No Cronos: 29 origens, horizonte 7, 203 previsões.
- Protocolos diferentes dão erros diferentes para o mesmo modelo (19,96 contra 11,76 no P3). Sempre rotule o protocolo.
- Vale para classificação também. A divisão aleatória não é uma versão otimista: é outra pergunta.

IV

PARTE QUARTA

Apontar o caso

xv Classificação: prever um rótulo

xvi Features: transformar o mundo em coluna

xvii Vazamento: o erro que só aparece em produção

xviii Regressão logística

CAPÍTULO XV

Classificação: prever um rótulo

da pergunta "quantos" para a pergunta "qual"

A Parte III respondeu quantos incidentes chegam amanhã. Nenhuma linha dela responde qual deles vai estourar. São perguntas de famílias diferentes, e a segunda é a que fecha a promessa do produto. Este capítulo troca a família.

§1 Regressão e classificação

Quando o que se quer prever é um número numa escala contínua — quantos incidentes, quantos reais, quantos minutos — o problema é de **regressão**. Foi o que a Parte III fez.

Quando o que se quer prever é a qual categoria o caso pertence — vai estourar ou não, é spam ou não, o cliente vai cancelar ou não — o problema é de **classificação**. O caso mais comum, e o nosso, tem só duas categorias: chama-se classificação binária.

A diferença não é cosmética. Muda o alvo, muda o algoritmo, muda a métrica de avaliação e, principalmente, muda o que significa errar. Errar por 3 incidentes é um erro pequeno; classificar como seguro um chamado que estourou é um erro categórico.

GLOSSÁRIO

Aprendizado supervisionado. Você mostra ao algoritmo casos passados *com a resposta certa* e ele aprende a regra. Regressão e classificação são os dois tipos.

Classe positiva. O evento que interessa detectar. Aqui, a violação de OLA — mesmo sendo a notícia ruim, é ela a "positiva".

Prevalência. Que fração dos casos é da classe positiva. No Cronos, 0,97%.

§2 O modelo não devolve o rótulo, devolve uma probabilidade

Aqui está o ponto que mais gera confusão, e o mais útil de entender.

Um classificador binário não responde "sim" ou "não". Ele devolve um número entre 0 e 1: a probabilidade estimada de o caso ser da classe positiva. Quem transforma esse número em decisão é você, escolhendo um **limiar de corte**.

O padrão de toda biblioteca é cortar em 50%: acima disso, sinaliza. Esse padrão é arbitrário e, em evento raro, é quase sempre a escolha errada — o capítulo XX mostra o estrago que ele faz.




Fig. 15.1 O modelo produz a régua de probabilidade. O limiar é uma decisão de negócio colocada em cima dela, e pode ser mudado a qualquer momento sem retrainar nada.

NA VIDA REAL

Exame de sangue para uma doença. O laboratório não mede "tem" ou "não tem": mede uma concentração, um número contínuo. Alguém decidiu que acima de certo valor o resultado sai como positivo.

Baixar esse valor de corte detecta mais doentes de verdade e também manda mais gente saudável fazer exame de novo, à toa. Subir faz o contrário. O aparelho é o mesmo nos dois casos — o que muda é quanto susto desnecessário a sociedade aceita para não perder um caso real.

É exatamente a mesma escolha que se faz na fila de incidentes.

§3 Ordenar vale mais que classificar

Existe um terceiro uso, que costuma ser o mais valioso na operação e o menos falado nos cursos: nem sempre você quer um rótulo. Muitas vezes você quer uma *fila*.

Se o analista consegue olhar 50 chamados com atenção por dia, a

pergunta útil não é "quais são positivos", é "quais são os 50 mais prováveis". Aí o limiar some do problema e o que importa é só a ordem que o modelo produz.

Essa mudança de enquadramento é a base do capítulo XXII e é o que torna útil um modelo cuja probabilidade máxima é de 56%: nenhum caso passa de 50% com folga, e ainda assim a ordenação funciona.

NO CRONOS · O DESENHO DO PROBLEMA

- **Alvo:** o campo oficial KPI Violado?, que a Locaweb já preenche. Não reimplementamos a regra.
- **Uma linha, um incidente.** Nada de agregação por dia: a pergunta é sobre o caso individual.
- **248 quebras em 25.600 incidentes**, prevalência de 0,97% — uma quebra a cada 103 incidentes.
- **Validação por data:** treino com 20.417 incidentes até 30/09 (198 quebras), teste com 5.183 do último trimestre (50 quebras).
- **Uso pretendido:** fila ordenada por risco, não carimbo de "vai estourar". O risco máximo estimado no teste foi de 56,1%, e a mediana, 0,35%.

COMO PEDIR

"Trata como classificação binária e me devolve a probabilidade, não o rótulo. E antes de escolher qualquer limiar, me diz quantos casos por dia a operação consegue olhar — o corte sai daí, não do padrão da biblioteca."

REVISÃO RÁPIDA

- Regressão prevê número em escala contínua; classificação prevê a qual categoria o caso pertence.
- O classificador devolve probabilidade. O rótulo só existe depois que alguém escolhe um limiar.
- O limiar padrão de 50% é arbitrário e costuma ser errado em evento raro.
- Muitas vezes o produto é a fila ordenada, não o rótulo — e aí o limiar deixa de importar.
- No Cronos: alvo KPI Violado?, 248 quebras em 25.600, corte de validação em 30/09.

CAPÍTULO XVI

Features: transformar o mundo em coluna

o algoritmo só enxerga número, e alguém precisa fazer a tradução

Algoritmo nenhum entende "produto Isin" ou "equipe Team11". Ele entende matriz de números. A tradução de um lado para o outro é onde mora a maior parte do trabalho real e onde se ganha ou se perde desempenho — no Cronos, 10 características viraram 136 colunas.

§1 Os três tipos de coluna e o que fazer com cada um

Uma coluna **numérica** já está pronta para entrar, mas costuma precisar de escala. Se uma coluna vai de 0 a 24 e outra vai de 0 a 100 mil, alguns algoritmos tratam a segunda como mais importante só pelo tamanho do número. Padronizar coloca todas na mesma régua.

Uma coluna **categórica** precisa virar número, e aqui há uma armadilha. A tentação é numerar: produto A vira 1, produto B vira 2, produto C vira 3. Não faça isso. O modelo vai concluir que C é o triplo de A e que B fica no meio do caminho entre os dois, o que não quer dizer nada.

Uma coluna de **data** não entra como data. Ela vira várias colunas derivadas: dia da semana, hora, é feriado, é fim de mês. A data crua tem pouca informação; o calendário que se extrai dela tem muita.

§2 One-hot: uma coluna por valor

A solução padrão para categoria é criar uma coluna nova para cada valor possível, cada uma valendo 1 ou 0. Chama-se *one-hot encoding*, ou codificação um-de-n.

Assim nenhum valor fica "maior" que outro: eles ficam simplesmente diferentes. O preço é o tamanho — uma coluna com 45 valores distintos vira 45 colunas.

O QUE O SISTEMA REGISTRA

INC8595245 · P3 · produto lsin · categoria cat31 · equipe Team11 · sábado · 19h · abertura manual

↓ tradução

O QUE O ALGORITMO RECEBE

produto=lsin 1	produto=lssl 0	produto=lvps 0	...mais 42 0	hora 19	dia_semana 5
-------------------	-------------------	-------------------	-----------------	------------	-----------------

Só a coluna do valor presente recebe 1. Todas as outras recebem 0 — por isso o nome "um de n".

NO CRONOS: 10 características → 136 colunas
Prioridade 2 · Grupo 16 · Aberto por 2 · Produto 45 · Categoria 119 · Subcategoria 383 · Ativo 4.665 + 3 numéricas

Fig. 16.1 A tradução de uma linha real. Repare que as sete categorias somam muito mais que 136 valores possíveis — o §3 explica o que foi feito com as de cardinalidade alta.

§3 Quando a categoria tem milhares de valores

O one-hot funciona bem até umas dezenas de valores. Com milhares, ele quebra: a coluna Item de configuração tem **4.665** valores distintos. Uma coluna por ativo produziria uma matriz gigante em que quase todo ativo aparece meia dúzia de vezes.

O problema não é o tamanho do arquivo, é estatístico: com poucos exemplos por valor, o modelo aprende o acaso daqueles poucos casos. E qualquer ativo que apareça pela primeira vez em produção não teria coluna nenhuma.

Duas saídas comuns: manter só os valores frequentes e jogar o resto num balde de "outros", ou trocar a categoria por uma estatística dela — por exemplo, a taxa histórica de quebra daquele ativo. A segunda é poderosa e perigosa, porque se a taxa for calculada usando o próprio caso, você acabou de criar um vazamento. O próximo capítulo trata disso.

NA VIDA REAL

Uma ficha de proposta de crédito é exatamente isso. Renda e idade entram como número. Estado civil e profissão viram caixinhas de marcar, uma por opção — ninguém escreveria "solteiro = 1, casado = 2, viúvo = 3", porque não faz sentido dizer que viúvo é o triplo de solteiro.

E o CEP, que tem dezenas de milhares de valores, nunca entra inteiro: vira região, ou vira uma estatística da região. É o mesmo problema de cardinalidade alta, resolvido do mesmo jeito.

§4 Valor faltante

Base real tem buraco. Ou você preenche, ou o algoritmo recusa a linha inteira.

Preencher com a média é o reflexo mais comum, e às vezes é errado. A pergunta anterior é: *por que está faltando?* Se o campo Solução está vazio em 61% dos incidentes, isso não é ruído — é informação sobre como a operação trabalha, e a ausência em si pode ser o sinal mais forte da coluna.

Notebook 04, seções 4.2 e 4.10.2.

NO CRONOS · AS 10 CARACTERÍSTICAS E O QUE FICOU DE FORA

Entraram só características disponíveis *no instante da abertura*: prioridade, grupo designado, quem abriu, produto, categoria, subcategoria, item de configuração, hora, dia da semana e feriado.

Ficaram de fora, por regra explícita: duração, data de resolução, data de encerramento, status e código de fechamento. Todas existem na base e todas descrevem o que aconteceu *depois*.

Testamos ainda quatro características de estado — quantos incidentes o ativo teve nos últimos 30 dias, quantas quebras teve em 90, quantos chamados o time tinha abertos naquele momento e o volume do dia. O ganho foi marginal: ROC AUC de 0,8693 para 0,8793 e PR-AUC de 0,2958 para 0,2982, sem mexer no top 50. Não compensaram a complexidade de calcular estado histórico em produção.

COMO PEDIR

"Lista todas as colunas candidatas e, para cada uma, diz o tipo, a cardinalidade e se ela existe no instante da decisão. Categoria nunca vira número ordenado. Para as de cardinalidade alta, me apresenta a estratégia antes de aplicar."

REVISÃO RÁPIDA

- Numérica precisa de escala; categórica precisa de one-hot; data vira várias colunas de calendário.
- Numerar categoria cria uma ordem falsa. One-hot cria uma coluna por valor, cada uma 0 ou 1.
- Cardinalidade alta quebra o one-hot: 4.665 ativos não viram 4.665 colunas úteis.
- Antes de preencher valor faltante, pergunte por que está faltando. A ausência pode ser o sinal.
- No Cronos: 10 características viraram 136 colunas, todas disponíveis na abertura.

CAPÍTULO XVII

Vazamento: o erro que só aparece em produção

quando o modelo já sabe a resposta

Existe uma categoria de erro que não produz mensagem de erro, não aparece na validação e faz o modelo parecer excelente. Ele só se revela no dia em que o sistema entra no ar e não funciona. No Cronos, quatro colunas da base tinham essa propriedade — e uma delas praticamente define o alvo.

§1 O que é vazamento

Vazamento, ou *data leakage*, é quando uma informação que não existiria no momento da decisão entra no treino do modelo. O modelo aprende com ela, acerta muito, e no uso real essa informação não está disponível — ou pior, ela só existe *porque* o evento já aconteceu.

O sintoma clássico é um resultado bom demais. Quando um modelo aparece com desempenho quase perfeito num problema que os especialistas consideram difícil, a primeira hipótese não deve ser genialidade: deve ser vazamento.

NA VIDA REAL

Você quer prever quais alunos vão reprovar, para oferecer reforço em março. Monta o modelo com as colunas da secretaria e ele acerta 99%. Comemora.

Aí alguém percebe que uma das colunas era "quantas provas finais o aluno fez". Só faz prova final quem já estava reprovando. O modelo não previu nada — ele leu a resposta numa coluna com outro nome.

E o detalhe cruel: em março, quando o reforço precisa ser oferecido, essa coluna está vazia para todo mundo. O modelo de 99% vale zero exatamente no instante em que seria usado.

§2 A pergunta que resolve

Existe um teste único que pega quase todo vazamento, e ele não é estatístico. Para cada coluna, pergunte:

No exato instante em que eu preciso da previsão, esse campo já está preenchido?

Se a resposta for não, ou "depende", a coluna sai. Não importa o quanto ela ajuda — quanto mais ela ajudar, mais suspeita ela é.




Fig. 17.1 A linha do tempo de um incidente. Tudo à direita da linha azul só passa a existir depois da decisão. As quatro colunas em vermelho foram proibidas por regra escrita no notebook.

§3 O caso mais grave: quando a coluna é o alvo

Nem todo vazamento é igual. O pior tipo é quando a coluna proibida *define* o alvo por construção.

A violação de OLA, no dataset da Locaweb, é a duração ultrapassar um prazo. Então prever violação usando a duração não é uma vantagem injusta: é copiar a resposta e apresentar como previsão.

Medimos o quanto isso é literal.

PRIORIDADE 2 · FAIXA DE DURAÇÃO	INCIDENTES	QUEBRAS	TAXA
até 1h	4.094	0	0,0%
1 a 4h	1.007	0	0,0%
4 a 12h	48	35	72,9%
12 a 24h	4	4	100,0%

Notebook 04, seção 4.2.1. A menor duração entre as quebras de P2 é de 4,0 horas.

Nenhum incidente de P2 com menos de 4 horas quebrou, e a taxa salta para 73% logo depois. Um modelo com acesso à duração aprenderia a regra "passou de 4h, quebrou" e chegaria perto de 100% de acerto — sem prever nada, porque quando a duração é conhecida o prazo já estourou.

NO CRONOS · O USO LEGÍTIMO DAQUELA MESMA TABELA

A tabela acima é imprestável como entrada de modelo e valiosa como *diagnóstico*. Foi dela que inferimos o prazo real de OLA, que não está escrito em lugar nenhum do dataset: em torno de 4 horas no P2 e de 8 horas no P3, já que a menor duração entre as quebras de P3 é de 8,7 horas.

Esse número virou insumo do produto: sem ele não dá para dizer quanto tempo de antecedência um alerta oferece. A mesma coluna que envenena o treino sustenta o desenho do alerta.

ATENÇÃO · OS VAZAMENTOS QUE PASSAM DESPERCEBIDOS

Nem todo vazamento é uma coluna óbvia. Três formas discretas de criar um:

- **Estatística calculada no conjunto todo.** Se você substitui o ativo pela taxa histórica de quebra dele, e essa taxa foi calculada com os dados de teste dentro, o teste contaminou o treino.
- **Padronizar antes de separar.** Calcular média e desvio no conjunto completo e só depois cortar treino e teste vaza informação do teste, de forma pequena mas real.
- **Escolher a configuração olhando o teste.** É vazamento de decisão, não de coluna. Foi o que fizemos no ajuste do Prophet, e está declarado como limitação em vez de escondido.

COMO PEDIR

"Antes de treinar, passa coluna por coluna e diz se ela existe no instante da decisão. Proíbe explicitamente as que não existem, escreve a lista no notebook, e calcula qualquer estatística de apoio só dentro do treino."

REVISÃO RÁPIDA

- Vazamento é informação do futuro dentro do treino. Não dá erro, e some quando o sistema entra no ar.
- Resultado bom demais é sintoma de vazamento, não de talento.
- Teste único: no instante da decisão, esse campo já está preenchido?
- No Cronos: duração, resolvido, encerrado e status proibidos — a violação é derivada de duração.
- A mesma coluna proibida no treino serviu de diagnóstico: prazo de ~4h no P2 e ~8h no P3.

CAPÍTULO XVIII

Regressão logística

a reta que vira probabilidade

É o algoritmo de classificação mais antigo em uso corrente, é o mais simples da lista, e foi o escolhido para o Cronos depois de empatar com o XGBoost em uma métrica e ganhar dele na outra. Este capítulo explica como ela funciona e por que a simplicidade dela não é uma concessão.

§1 Por que uma reta não serve

O caminho mais direto seria ajustar uma reta que devolve 0 para "não quebrou" e 1 para "quebrou". Duas coisas quebram essa ideia.

A primeira é que a reta não tem limite: para valores extremos das entradas, ela devolve 1,4 ou $-0,3$, e probabilidade não pode passar de 1 nem ficar negativa.

A segunda é mais sutil e mais importante. A reta assume que cada unidade a mais na entrada muda a saída sempre na mesma medida. Mas perto da certeza isso não vale: sair de 90% para 95% de risco é muito mais difícil do que sair de 45% para 50%.

§2 A curva em S

A regressão logística resolve os dois problemas passando o resultado da reta por uma função em forma de S, chamada sigmoide. Ela pega qualquer número, de menos infinito a mais infinito, e devolve algo entre 0 e 1.

O comportamento dessa curva é o que a torna adequada: no meio ela é íngreme, e nas pontas ela achata. Ou seja, quando o modelo está em dúvida, uma informação nova muda muito a probabilidade; quando ele já está quase certo, muda pouco. É exatamente como funciona convencer alguém.




Fig. 18.1 A mesma soma ponderada, passada por uma reta e por uma sigmoide. Só a segunda produz algo que pode ser lido como probabilidade.

§3 O que o modelo aprende: um peso por coluna

O treino consiste em achar um número — um peso — para cada uma das 136 colunas. A previsão é a soma de todos os pesos das colunas ativas naquele incidente, passada pela sigmoide.

Essa estrutura é o motivo pelo qual a logística é explicável de nascença. Não é preciso ferramenta externa para descobrir por que o modelo deu 56% a um incidente: basta ler quanto cada coluna contribuiu para a soma. A explicação é exata, não é aproximação.

Os pesos costumam ser lidos como **razão de chances**, ou *odds ratio*: quanto aquela característica multiplica a chance do evento. Um peso que multiplica por 3 significa que, mantido o resto igual, aquela característica torna a quebra três vezes mais provável.

Notebook 04, seções 4.9.1 e 4.9.2.

NO CRONOS · A DECOMPOSIÇÃO DE UM CASO REAL

O incidente de maior risco do período de teste recebeu 56,1% — e estourou de fato. A pontuação dele se decompõe assim, a partir de um ponto de partida de 0,41%, que é o risco do incidente médio:

- categoria cat31 · multiplica por **8,95** · responde por 38% da explicação
- produto lsin · multiplica por 3,11 · 19%
- subcategoria sub388 · multiplica por 2,04 · 12%
- equipe Team11 · multiplica por 1,92 · 11%
- sábado · multiplica por 1,57 · 8%

O erro máximo dessa reconstrução é da ordem de 10^{-15} , ou seja, a decomposição é exata e não uma estimativa. Nos 300 primeiros da fila, as três principais características concentram 79% do peso, em média — o que torna a explicação curta o bastante para caber num alerta.

§4 O que a logística exige e o que ela não faz

Ela pressupõe que os efeitos se somam. Se a realidade tiver interação forte — a característica A só importa quando B também está presente — a logística não descobre isso sozinha, e é preciso criar a coluna da combinação à mão.

É essa a principal vantagem dos modelos de árvore, que capturam interação sem serem instruídos. No nosso caso essa vantagem não se materializou, e o capítulo XXV mostra os números.

ATENÇÃO · CARACTERÍSTICAS QUE CONTAM A MESMA HISTÓRIA

Quando duas colunas carregam informação parecida, o modelo distribui o peso entre elas, e cada peso isolado passa a enganar. Chama-se colinearidade.

Testamos removendo a categoria, que era a característica de maior peso: o risco daquele incidente caiu de 56,1% para 18,5%, mas os pesos das outras *subiram* para compensar — produto de 3,11 para 3,81, equipe de 1,92 para 2,46. E o modelo inteiro piorou pouco: ROC AUC de 0,869 para 0,852.

Leitura: nenhuma característica sozinha explica o resultado, e ler um peso isolado como "a causa" é erro. Elas se sustentam em conjunto.

COMO PEDIR

"Começa pela regressão logística e me mostra a decomposição de alguns casos concretos, com o quanto cada característica multiplica a chance. Se um modelo mais complexo for testado depois, quero a comparação lado a lado, não a troca direta."

REVISÃO RÁPIDA

- Uma reta não serve para probabilidade: passa de 100%, fica negativa e trata todas as faixas como iguais.
- A sigmoide comprime qualquer número em 0–100%: íngreme na dúvida, achatada na quase certeza.
- O modelo aprende um peso por coluna; a previsão é a soma dos pesos ativos passada pela sigmoide.
- Por isso a explicação é exata: dá para ler a contribuição de cada característica sem ferramenta externa.
- Ela não captura interação sozinha, e pesos individuais enganam quando as colunas se sobrepõem.

V

PARTE QUINTA

Medir direito

xix Evento raro e por que a acurácia mente

xx Matriz de confusão e o limiar de corte

xxi ROC, AUC e PR-AUC

xxii Curva de ganho e a leitura por triagem

xxiii Calibração e explicabilidade

CAPÍTULO XIX

Evento raro e por que a acurácia mente

99% de acerto sem nenhum modelo

Um programa de uma linha, que responde "não vai quebrar" para todo incidente sem olhar nada, acerta 99,04% dos casos da nossa base. É mais do que o nosso modelo acerta. Entender por que isso acontece, e por que não significa nada, é o conceito mais importante da Parte V.

§1 Acurácia é a fração de acertos

Acurácia é a métrica mais intuitiva que existe: de todos os casos, quantos o modelo classificou certo. É por isso que ela aparece em toda reportagem sobre inteligência artificial.

E é por isso que ela engana em quase todo problema que vale a pena resolver. Porque os problemas que valem a pena costumam ser sobre eventos raros: fraude, doença, falha, cancelamento, violação de prazo. O evento comum, ninguém precisa de modelo para prever.

§2 A conta que revela o problema

Na base do Cronos, 248 dos 25.600 incidentes violaram o OLA. Isso é 0,97% — uma quebra a cada 103 incidentes.

Agora considere o classificador mais burro possível: ele responde "não quebra" sempre. Ele erra as 248 quebras e acerta todo o resto. A acurácia dele é 99,03%.

Um modelo útil, que sinaliza os 518 casos mais arriscados, acerta menos: **90,16%**. Ele parece pior por uma métrica que não tem nada a ver com o problema.

OS 5.183 INCIDENTES DO PERÍODO DE TESTE

5.133 não quebraram	a faixa vermelha são as 50 quebras (0,96%)
---------------------	--

CLASSIFICADOR QUE NUNCA SINALIZA NADA

acerta os 5.133 · erra as 50 · não olha nenhuma coluna · custa zero	
ACURÁCIA 99,04%	QUEBRAS ENCONTRADAS: 0

MODELO SINALIZANDO OS 518 DE MAIOR RISCO

acerta 29 das 50 quebras · gera 489 alarmes falsos · dá trabalho	
ACURÁCIA 90,16%	QUEBRAS ENCONTRADAS: 29

Fig. 19.1 A métrica que premia o classificador inútil. Pela acurácia, não fazer nada ganha de 99,04% a 90,16%. Pela única coisa que importa — quantas quebras foram encontradas — o placar é 29 a 0.

NA VIDA REAL

Uma doença que atinge 1 pessoa em cada mil. Um médico que diga "você está saudável" para todo mundo que entra no consultório acerta 99,9% dos diagnósticos.

Ninguém aceitaria esse médico, e a razão é óbvia quando dita assim: os dois erros possíveis não têm o mesmo custo. Mandar para casa quem está doente é incomparavelmente pior do que pedir um exame a mais para quem está saudável.

A acurácia trata os dois erros como iguais. É essa a falha, e ela não se conserta escolhendo outro algoritmo — se conserta escolhendo outra métrica.

§3 O reflexo errado: balancear a classe

Diante do desbalanceamento, a receita mais divulgada é reequilibrar as classes: duplicar os casos raros, descartar parte dos comuns, ou dar mais peso ao raro no treino.

Funciona para alguns objetivos e tem um custo que raramente é

mentionado: o modelo passa a superestimar a probabilidade do evento. Ele foi treinado num mundo artificial onde o evento é comum, e responde como se o mundo fosse aquele.

NO CRONOS · O BALANCEAMENTO INVIABILIZOU O PRODUTO

Testamos o XGBoost com peso na classe rara. O efeito na ordenação foi negativo — PR-AUC caiu de 0,2526 para 0,2367 e as quebras encontradas no top 50 caíram de 14 para 12.

Mas o estrago sério foi outro. Somando as probabilidades que o modelo atribuiu a cada incidente do teste, ele previu **1.007 quebras onde ocorreram 50**.

Isso destrói uma entrega inteira: a projeção de atingimento do KPI (capítulo XXVII) funciona somando probabilidades. Com esse modelo, ela apontaria uma catástrofe vinte vezes maior que a realidade todo mês. A regressão logística, sem balanceamento nenhum, prevê 48,1 contra 50 observadas.

Notebook 04, seção 4.7.

ATENÇÃO · QUANDO BALANCEAR FAZ SENTIDO

Não é uma técnica ruim, é uma técnica com pré-requisito. Ela ajuda quando você precisa de um rótulo e o algoritmo, deixado sozinho, nunca sinalizaria nada.

Ela atrapalha quando você precisa que a probabilidade signifique alguma coisa — para ordenar uma fila, para somar, para dizer ao analista "este caso tem 30% de chance". Decida isso *antes*, olhando o uso, e não depois olhando a métrica.

COMO PEDIR

"Não me reporta acurácia em evento raro. Quero prevalência, quantos positivos existem no teste, e a comparação contra o classificador que nunca sinaliza. Se for balancear a classe, me avisa antes e mede o efeito na soma das probabilidades."

REVISÃO RÁPIDA

- Acurácia trata todos os erros como iguais, e em evento raro isso premia quem não faz nada.
- No Cronos: prevalência 0,97%; não sinalizar nada dá 99,04% de acurácia contra 90,16% do modelo.
- O placar que importa é outro: 29 quebras encontradas contra zero.
- Balancear a classe rara distorce a probabilidade: o XGBoost com peso previu 1.007 quebras onde houve 50.
- Decida se precisa de rótulo ou de probabilidade antes de balancear.

CAPÍTULO XX

Matriz de confusão e o limiar de corte

os quatro resultados possíveis, e quem escolhe onde cortar

Se a acurácia não serve, o que serve? A resposta começa por separar os erros em vez de somá-los. São quatro resultados possíveis, com custos completamente diferentes, e a régua que decide a proporção entre eles não é do modelo: é sua.


§1 Os quatro quadrantes

Toda decisão binária produz um de quatro resultados, e a tabela que os organiza chama-se matriz de confusão. O nome é infeliz e a ideia é simples.

Você acertou de dois jeitos: sinalizou e o caso quebrou (**verdadeiro positivo**), ou não sinalizou e o caso não quebrou (**verdadeiro negativo**).

E errou de dois jeitos: sinalizou e o caso não quebrou (**falso positivo**, o alarme falso), ou não sinalizou e o caso quebrou (**falso negativo**, a quebra que passou batido).

Os dois erros têm custos diferentes, e escrever esses custos é a parte do trabalho que não é técnica.



Números reais do teste, sinalizando os 518 incidentes de maior risco entre 5.183.

Fig. 20.1 A matriz de confusão do modelo do Cronos no corte de 518. Repare no tamanho do quadrante inferior direito: são 4.644 casos, e é o volume dele que faz a acurácia parecer alta em qualquer configuração.

§2 Precisão e cobertura

Dos quatro quadrantes saem as duas métricas que realmente se usam.

Precisão responde: dos casos que eu sinalizei, quantos eram de verdade? É a métrica de quem vai atender os alertas — ela mede o quanto o trabalho gerado é útil.

Cobertura — também chamada de *recall* ou sensibilidade — responde: de todas as quebras que existiram, quantas eu peguei? É a métrica de quem responde pela meta.

As duas se movem em direções opostas, sempre. Sinalizar mais casos aumenta a cobertura e derruba a precisão. É uma troca, não um problema a resolver.

§3 O limiar é uma decisão de negócio

O que move as duas ao mesmo tempo é o limiar. E vale insistir: *mudar o limiar não muda o modelo*. É a mesma fila, cortada em outro lugar. Você pode mudar de opinião amanhã sem retreinar nada.

CORTE	SINALIZADOS	QUEBRAS ACHADAS	PRECISÃO	COBERTURA
risco ≥ 50% (padrão)	2	2	100%	4%
os 50 de maior risco	50	15	30%	30%
os 100 de maior risco	100	17	17%	34%
os 518 de maior risco	518	29	5,6%	58%

Notebook 04, seção 4.6.2. Teste com 5.183 incidentes e 50 quebras.

NO CRONOS · O LIMIAR PADRÃO SERIA UM DESASTRE

Olhe a primeira linha. Com o corte padrão de 50% que vem em toda biblioteca, o modelo sinaliza **dois** incidentes no trimestre inteiro. Acerta os dois — precisão de 100% — e deixa passar 48 das 50 quebras.

Seria tecnicamente impecável e operacionalmente inútil. Ninguém monta um produto para receber dois alertas por trimestre.

A linha dos 50 é a que faz sentido para a operação: cabe no que um analista consegue olhar num dia, e um de cada três alertas é quebra de verdade — contra uma taxa base de 0,96%. É **31 vezes** melhor que sortear.

NA VIDA REAL

O detector de metal do aeroporto é o mesmo dilema, calibrado em público. Ele está regulado para apitar com moeda e fivela de cinto — precisão baixíssima, quase todo apito é falso alarme.

Ninguém acha isso um defeito, porque o custo dos dois erros é assimétrico e todo mundo entende a assimetria. Se o detector fosse regulado para só apitar com certeza, ele teria precisão perfeita e não serviria para nada.

Regular o detector é escolher o limiar. Não é uma decisão do fabricante do aparelho.

COMO PEDIR

"Me dá a matriz de confusão em três ou quatro cortes diferentes, com precisão e cobertura em cada um, e me deixa escolher olhando quantos casos por dia a operação aguenta. Nunca use o corte de 50% por padrão."

REVISÃO RÁPIDA

- Quatro resultados: verdadeiro positivo, falso positivo (alarme falso), falso negativo (o que passou) e verdadeiro negativo.
- Precisão: dos sinalizados, quantos eram de verdade. Cobertura: das quebras, quantas eu peguei.
- As duas se movem em sentidos opostos. É troca, não defeito.
- O limiar é decisão de negócio e não exige retreino.
- No Cronos, o corte padrão de 50% sinalizaria 2 casos no trimestre e perderia 48 das 50 quebras.

CAPÍTULO XXI

ROC, AUC e PR-AUC

medir o modelo sem escolher um limiar

Toda métrica do capítulo anterior depende de onde você corta. Existe uma família de medidas que avalia o modelo em todos os cortes ao mesmo tempo, e a mais famosa delas tem um defeito grave justamente em evento raro. Escolher a curva errada foi o que quase nos fez trocar de modelo.

§1 A ideia: varrer todos os limiares

Em vez de escolher um corte e medir ali, você percorre todos os cortes possíveis, do mais rigoroso ao mais frouxo, anota o desempenho em cada um e desenha a trajetória. O resultado é uma curva, e a área embaixo dela vira um número único.

A vantagem é comparar dois modelos sem depender de uma escolha operacional. A desvantagem é que o número resume tudo, inclusive faixas de corte que você jamais usaria.

§2 A curva ROC e o AUC

A curva ROC cruza a **cobertura** — que fração das quebras foi capturada — contra a **taxa de falso alarme**, que fração dos casos bons foi sinalizada à toa.

A área sob essa curva chama-se AUC, e ela tem uma leitura bonita: *é a probabilidade de o modelo dar uma nota maior a uma quebra sorteada do que a um caso bom sorteado*. AUC de 0,5 é sorteio puro. AUC de 1,0 é ordenação perfeita.

O AUC do nosso modelo é 0,869. Traduzindo: pegando ao acaso uma quebra e um não-quebra, em 87% das vezes o modelo dá risco maior à quebra.

§3 O defeito do AUC em evento raro


Aqui está o ponto do capítulo. A taxa de falso alarme tem no denominador *todos os casos bons* — 5.133 deles no nosso teste. Emitir 489 alarmes falsos representa 9,5% desse total: um número pequeno, que quase não mexe na curva.

Só que, para quem recebe os alertas, 489 falsos contra 29 acertos é uma

experiência péssima. O AUC não enxerga isso, porque ele dilui os alarmes falsos num denominador enorme.


A curva precisão-cobertura corrige exatamente isso, trocando o eixo do falso alarme pela precisão, cuja conta só envolve os casos que você sinalizou.

CURVA ROC · AUC 0,869



Parece excelente. O denominador do eixo x tem 5.133 casos bons, então 489 alarmes falsos mal deslocam a curva.

PRECISÃO-COBERTURA · PR-AUC 0,296



Mostra o preço real: para cobrir mais quebras, a precisão despenca. A régua de comparação aqui é 0,0096, não 0,5.

Fig. 21.1 O mesmo modelo, nas duas curvas. Formato esquemático; os valores de área são os medidos. A ROC compara contra o sorteio (0,5); a PR compara contra a taxa base do evento (0,0096).

Notebook 04, seções 4.6.3, 4.6.4 e 4.7.

NO CRONOS · A MÉTRICA DECIDIU A ESCOLHA DO MODELO

MODELO	ROC AUC	PR-AUC
Regressão logística	0,8693	0,2958
XGBoost	0,8679	0,2526

Pelo ROC AUC, empate técnico: a diferença está na terceira casa. Pelo PR-AUC, a logística é **17% melhor**.

Se a decisão tivesse sido tomada pelo AUC — que é a métrica que aparece por padrão em todo tutorial — os dois seriam intercambiáveis e o argumento cairia para "escolhemos o mais simples". Com o PR-AUC, a escolha do modelo linear não troca desempenho por simplicidade: ela ganha nas duas.

ATENÇÃO · PR-AUC NÃO SE COMPARA COM 0,5

Um PR-AUC de 0,296 parece baixo para quem está acostumado com AUC. Ele não é.

A régua da curva de precisão-cobertura é a prevalência do evento, que aqui é 0,0096. O modelo está **31 vezes acima** dessa régua. Comparar 0,296 com 0,5 e concluir "pior que o acaso" é ler a métrica errada — e é um erro fácil de cometer numa apresentação.

COMO PEDIR

"Em evento raro, reporta PR-AUC junto com ROC AUC, e sempre com a taxa base ao lado para eu saber contra o que comparar. Se os dois discordarem sobre qual modelo é melhor, o PR-AUC decide."

REVISÃO RÁPIDA

- As curvas varrem todos os limiares e resumem em uma área, evitando depender de um corte.
- AUC é a chance de o modelo dar nota maior a um positivo que a um negativo. 0,5 é sorteio.
- Em evento raro o AUC dilui o alarme falso num denominador enorme e parece melhor do que a experiência real.
- PR-AUC troca o falso alarme pela precisão e mostra o preço de cobrir mais.
- No Cronos: empate no AUC ($0,869 \times 0,868$) e 17% de vantagem da logística no PR-AUC ($0,296 \times 0,253$).

CAPÍTULO XXII

Curva de ganho e a leitura por triagem

a métrica que o gestor entende sem tradução

Nenhuma das métricas anteriores responde a pergunta que o gestor faz: se meu analista olhar 50 chamados por dia, quantas quebras ele acha a mais do que acharia sem o modelo? A curva de ganho responde isso em unidades de chamado, e foi ela que sustentou o projeto na defesa.

§1 Trocar a pergunta


Precisão, cobertura, AUC e PR-AUC são todas medidas de qualidade abstrata. A curva de ganho troca o enquadramento: dado que você vai percorrer a fila de cima para baixo, quantos positivos encontra em cada altura?

É a mesma informação, reorganizada na unidade de quem decide. E torna a comparação com a prática atual imediata, porque a prática atual também é uma fila — ordenada por outra coisa.

§2 A régua não é o acaso, é a prática atual

Aqui está o ponto que separa uma defesa sólida de uma frágil. É tentador comparar o modelo com a fila aleatória, porque a vantagem fica enorme. Só que ninguém trabalha em ordem aleatória.

A comparação honesta é contra as regras que a operação já usa ou usaria sem esforço: ordenar por prioridade, ordenar pela taxa histórica de quebra do time, ou vigiar a lista dos ativos crônicos.



A distância entre a linha azul e a dourada é o valor que o modelo acrescenta sobre a prática disponível.

Fig. 22.1 Curva de ganho no trimestre de teste. Valores medidos no notebook 04, seção 4.5. O ganho é maior no topo da fila, que é justamente a parte efetivamente usada.

FILA PERCORRIDA	MODELO	POR TIME	POR PRIORIDADE	GANHO
50	15	6	1	+150%
100	17	8	2	+112%
250	22	14	4	+57%
1.000	36	28	8	+29%

Notebook 04, seção 4.5. "Ganho" é sobre o melhor baseline daquela linha.

NO CRONOS · O GANHO É MAIOR ONDE ELE É USADO

Repare que o ganho cai conforme a fila desce: 150% nos 50 primeiros e 29% nos mil primeiros. Isso é uma boa notícia disfarçada de má.

Quem percorre mil casos por trimestre já está olhando quase tudo, e aí qualquer ordenação converge. A parte da fila que a operação de fato usa é o topo — e é exatamente onde a vantagem é maior.

Vale notar também a linha da prioridade: ordenar por prioridade encontra **1 quebra** nos 50 primeiros, pior que o acaso. Não é acidente. A prioridade 2 tem prazo mais curto e atendimento mais rápido — mediana de 26 minutos contra 1h46 do P3 — então a prioridade alta acaba tendo taxa de quebra *menor*: 0,81% contra 1,01%.

NA VIDA REAL

Uma operação de cobrança com 100 mil clientes inadimplentes e uma equipe que consegue ligar para 2 mil por dia. A pergunta nunca é "quem vai pagar" — é "para quais 2 mil eu ligo hoje".

A curva de ganho responde em unidades de ligação: com a lista atual a equipe recupera tantos contratos; com a lista ordenada pelo modelo, recupera tantos outros, no mesmo esforço. O gestor não precisa entender de AUC para decidir com esse número.

ATENÇÃO · A RÉGUA TRIVIAL PODE SER MUITO FORTE

No capítulo VI vimos que 30 ativos concentram 61,7% das quebras. Um baseline de "vigie os ativos crônicos" existe e é bom em fila longa: nos 518 primeiros ele encontra 16 quebras.

Mas nos 50 primeiros ele encontra **zero**, porque no início da fila ele não tem como desempatar entre os casos dos mesmos ativos. É por isso que baseline se mede na altura de fila que a operação usa, e não numa altura conveniente.

COMO PEDIR

"Monta a curva de ganho comparando o modelo com as regras simples que a operação já poderia usar, e mede tudo na altura de fila que a equipe realmente percorre. Quero o resultado em quebras encontradas, não em pontos de AUC."

REVISÃO RÁPIDA

- A curva de ganho responde na unidade da operação: quantos positivos em cada altura de fila.
- A régua é a prática atual, não o acaso — ninguém trabalha em ordem aleatória.
- No Cronos: 15 quebras nos 50 primeiros contra 6 da melhor regra simples.
- O ganho cai conforme a fila desce, e é maior no topo, que é a parte usada.
- Ordenar por prioridade encontra 1 em 50 — pior que o acaso, porque P2 é atendido mais rápido.

CAPÍTULO XXIII

Calibração e explicabilidade

a probabilidade quer dizer o que diz, e dá para saber por quê

Um modelo pode ordenar a fila perfeitamente e ainda assim mentir nos números que exhibe. E pode acertar tudo sem que ninguém consiga dizer por quê — o que, numa operação, é motivo suficiente para o alerta ser ignorado. Este capítulo fecha a Parte V com as duas propriedades que transformam um modelo em produto.

§1 Ordenar e calibrar são coisas diferentes

Um modelo está **bem ordenado** quando os casos mais arriscados aparecem primeiro. Está **calibrado** quando o número que ele exhibe corresponde à realidade: de cada cem casos aos quais ele atribui 30%, cerca de trinta devem de fato acontecer.

Dá para ter uma coisa sem a outra. Um modelo que multiplica todos os riscos por dez ordena exatamente igual e mente em todos os números. AUC e PR-AUC não notam a diferença — elas só olham a ordem.

Calibração importa em três situações: quando o número aparece na tela para um humano decidir, quando probabilidades são somadas, e quando o corte é definido por um valor de risco em vez de por quantidade de casos.


NA VIDA REAL

A previsão do tempo é o exemplo canônico, e é um dos poucos campos que audita a própria calibração publicamente.

Quando o serviço diz "70% de chance de chuva", a promessa é: entre todos os dias em que eu disse 70%, choveu em cerca de 70% deles. Isso é verificável, e é verificado. Um serviço que dissesse 70% em dias que chovem 30% das vezes estaria bem ordenado — os dias de 70% ainda seriam mais chuvosos que os de 20% — e completamente descalibrado.

§2 Como se mede

Agrupe os casos por faixa de risco informado e compare, em cada faixa, o informado com o observado. Se as duas colunas andam juntas, o modelo está calibrado naquela faixa.



Na faixa mais alta o modelo subestima o risco pela metade. O desvio é para o lado seguro, e é desvio.

Fig. 23.1 Calibração do modelo no trimestre de teste, por faixa de risco. As cinco primeiras faixas cobrem 5.152 dos 5.183 incidentes; a última tem apenas 31 casos, e a incerteza ali é grande.

NO CRONOS · CALIBRADO ATÉ 5%, CONSERVADOR ACIMA

Nas faixas que concentram quase toda a base, o informado e o observado praticamente coincidem: 0,7 contra 0,9; 1,4 contra 1,4; 3,0 contra 2,7.

Na faixa acima de 10% o modelo informa 20,3% e observa-se 41,9%. Ele *subestima* o próprio acerto no topo da fila. Para o produto isso é o lado seguro do erro — o alerta entrega mais do que promete —, mas é um desvio e está declarado.

A consequência mais importante da calibração é outra: como a probabilidade é honesta, ela pode ser **somada**. A soma dos riscos de todos os incidentes do teste dá 48,1 e ocorreram 50 quebras, erro de 3,8%. É esse mecanismo que sustenta a projeção do capítulo XXVII — e é exatamente ele que o balanceamento de classe destruiria.

Notebook 04, seção 4.8.

§3 **Explicabilidade: por que este caso**

Um alerta que diz apenas "risco alto" é ignorado na segunda semana. O analista precisa de motivo para agir, e precisa poder discordar.

Existem duas famílias de explicação. A **global** responde o que o modelo aprendeu em geral — quais características pesam mais. A **local** responde por que *este* caso recebeu *esta* nota. É a local que vai para a tela.

Em modelos complexos, a explicação local precisa ser estimada por ferramentas externas, sendo o SHAP a mais conhecida. Na regressão logística ela é exata e sai de graça, porque o modelo já é uma soma de contribuições.

NO CRONOS · O QUE VAI PARA A TELA

O alerta do incidente de maior risco do período ficou assim:

- **56,1% de chance de estourar**, contra 0,97% de média da base. O contraste é parte da mensagem: sem ele, 56% não significa nada para quem lê.
- **1º de 5.183 incidentes do período**. A posição na fila é mais acionável que a probabilidade.
- **Evidência histórica**: dos 66 incidentes do ativo IC00840, 21 estouraram — 31,8%. Isso não vem do modelo, vem de uma contagem no histórico, e serve para o analista conferir.
- **Motivos**: categoria cat31 (38%), produto lsin (19%), subcategoria sub388 (12%).

Nos 300 primeiros da fila, todos têm histórico suficiente para uma evidência dessas, e as três principais características concentram 79% do peso. A explicação cabe em três linhas.

ATENÇÃO · EXPLICAÇÃO NÃO É CAUSA

Dizer que a categoria cat31 responde por 38% do risco significa que, no histórico, incidentes dessa categoria estouram mais. Não significa que a categoria *causa* o estouro.

A prova de que a leitura causal não se sustenta está no próprio modelo: removendo a categoria, os pesos das outras características sobem para compensar e o desempenho quase não muda. Se cat31 fosse a causa, remover a coluna derrubaria o modelo.

A palavra certa em tela é "motivo" ou "fator", nunca "causa". O capítulo XXVIII volta a esse tema.

COMO PEDIR

"Mede a calibração por faixa de risco, comparando informado com observado, e me diz até onde ela vale. Para a tela, quero risco, posição na fila, evidência histórica contável e os três principais fatores — chamados de fatores, não de causas."

REVISÃO RÁPIDA

- Ordenar bem e calibrar bem são propriedades distintas; AUC e PR-AUC só medem a primeira.
- Calibração importa quando o número aparece na tela, quando é somado, ou quando o corte é por valor de risco.
- Mede-se agrupando por faixa e comparando informado com observado.
- No Cronos: calibrado até 5%, conservador acima; soma de probabilidades dá 48,1 contra 50 observadas.
- Explicação local é a que vai para a tela. Na logística ela é exata. E explicação não é causa.

VI

PARTE SEXTA

Costurar

xxiv Aprendizado não supervisionado e clusterização

xxv Quando o modelo complexo não paga

xxvi Índice composto: construir uma nota

xxvii Compor modelos sem extrapolar nenhum

CAPÍTULO XXIV

Aprendizado não supervisionado e clusterização

agrupar sem resposta certa — e reconhecer quando não há grupo

Até aqui todo modelo aprendeu com a resposta certa em mãos. Existe uma família inteira que trabalha sem gabarito: ela procura estrutura no dado por conta própria. É poderosa, é sedutora, e tem uma armadilha específica — ela sempre devolve grupos, mesmo quando não existem.

§1 Sem gabarito

No aprendizado supervisionado você mostra casos com a resposta e o modelo aprende a prever. No **não supervisionado** não há resposta: você entrega os dados e pede que o algoritmo encontre alguma organização.

A tarefa mais comum é a **clusterização**: separar os casos em grupos de tal forma que cada grupo seja internamente parecido e diferente dos outros.

A dificuldade fundamental é que não existe erro a medir. Sem gabarito, não há como dizer que o agrupamento está errado — só se pode avaliar se ele é *coeso*.

§2 K-means, em uma página

O algoritmo mais usado funciona assim: você diz quantos grupos quer, ele sorteia esse número de pontos como centros, atribui cada caso ao centro mais próximo, recalcula os centros como a média dos casos atribuídos, e repete até parar de mudar.

Repare no detalhe que decide tudo: *você diz quantos grupos quer*. O algoritmo não descobre o número de grupos, ele obedece. Se você pedir cinco grupos num dado sem estrutura nenhuma, recebe cinco grupos.

NA VIDA REAL

Peça a alguém para separar em três montes uma pilha de moedas idênticas. A pessoa vai conseguir — vai fazer três montes com quantidades parecidas, e eles serão perfeitamente arbitrários.

Agora peça para separar moedas de 5, 25 e 50 centavos. Também três montes, e desta vez os montes existiam antes do pedido.


O algoritmo não distingue as duas situações. Nos dois casos ele entrega três montes com a mesma cara de resultado. Quem precisa distinguir é você, e o instrumento para isso é o §3.

§3 Silhueta: o grupo existe mesmo?


A silhueta é uma nota, entre -1 e 1 , que compara duas distâncias para cada caso: o quanto ele está perto dos colegas do próprio grupo e o quanto está perto do grupo vizinho mais próximo.

Perto de 1 significa que os grupos são nítidos. Perto de 0 significa que os casos estão na fronteira, ou seja, que a divisão é arbitrária. Negativo significa que os casos estariam melhor no grupo vizinho.

Não existe corte oficial, e a leitura prática usual é: acima de $0,5$ há estrutura razoável; entre $0,25$ e $0,5$, fraca; abaixo de $0,25$, não há grupo, há uma nuvem contínua que o algoritmo repartiu por obediência.

GRUPOS REAIS · silhueta alta

o espaço entre os grupos é maior
que o espaço dentro deles

NUVEM CONTÍNUA · silhueta ~0,13

as cores existem, as fronteiras não:
o algoritmo cortou onde mandaram

Ilustração do conceito. A silhueta de 0,13 é a medida real do teste de clusterização do Cronos.

Fig. 24.1 Os dois casos produzem exatamente a mesma saída: três grupos com rótulos. Só a silhueta distingue um do outro.

NO CRONOS · A CLUSTERIZAÇÃO FOI TESTADA E DESCARTADA

A ideia era agrupar produtos por formato da curva de incidentes ao longo do tempo, usando uma medida de distância própria para séries — *dynamic time warping*, que compara curvas permitindo esticar e encolher o eixo do tempo, para reconhecer o mesmo padrão mesmo deslocado.

O resultado foi silhueta de aproximadamente **0,13**. Os grupos não existiam: o algoritmo repartiu uma nuvem contínua porque foi mandado repartir.

A decisão foi descartar, e é uma decisão que se defende melhor do que parece. O desafio exigia "classificação ou clusterização", e a tentação de manter uns gráficos coloridos de clusters era real. Entregar um agrupamento sem estrutura seria entregar uma ilustração se passando por resultado. O requisito passou a ser atendido pelo classificador de risco de OLA, que tem gabarito e tem métrica.

ATENÇÃO · O ALGORITMO NUNCA DIZ "NÃO ACHEI NADA"

Este é o risco central da família não supervisionada, e vale para além do k-means: o método sempre devolve um resultado com aparência de descoberta. Segmentação de clientes, agrupamento de produtos, detecção de padrões — em todos, a saída é bonita mesmo quando não há sinal.

A defesa é sempre medir a coesão antes de interpretar os grupos. E vale outra regra prática: se você não consegue nomear os grupos encontrados de forma que a área de negócio reconheça, provavelmente não há grupos.

COMO PEDIR

"Se for clusterizar, me dá a silhueta antes de qualquer interpretação, testada em vários números de grupos. Se ficar abaixo de 0,25, escreve que não há estrutura em vez de apresentar os grupos."

REVISÃO RÁPIDA

- Não supervisionado trabalha sem resposta certa; a tarefa mais comum é clusterizar.
- O k-means obedece ao número de grupos que você pedir — ele não descobre esse número.
- Silhueta mede coesão: acima de 0,5 há estrutura; abaixo de 0,25 não há.
- No Cronos: silhueta ~0,13 com DTW, e a clusterização foi descartada.
- O algoritmo nunca diz "não achei nada". Medir a coesão antes de interpretar é obrigatório.

CAPÍTULO XXV

Quando o modelo complexo não paga

árvores, ensembles, e a conta que raramente é feita

XGBoost ganha competição de ciência de dados há anos e é a escolha automática de quase todo mundo. No Cronos ele perdeu para uma regressão logística de 1958. Este capítulo explica como os modelos de árvore funcionam, por que costumam ganhar, e o que precisa acontecer para que não ganhem.

§1 Árvore de decisão

Uma árvore é uma sequência de perguntas de sim ou não. "A prioridade é 3? Se sim, o produto é lsin? Se sim, a equipe é Team11?" Cada resposta leva a um ramo, e no fim de cada caminho existe uma estimativa.

A vantagem estrutural aparece nessa descrição: a árvore captura **interação** de graça. O efeito de ser Team11 pode ser diferente dentro do ramo do lsin e dentro do ramo de outro produto. A regressão logística, que soma efeitos, precisaria que alguém criasse a coluna da combinação à mão.

A desvantagem é que uma árvore sozinha decora. Ela vai partindo os dados até cada folha ter poucos casos, e aí aprendeu o acaso.

§2 Ensemble: muitas árvores fracas

A solução foi combinar muitas árvores. A **floresta aleatória** treina centenas de árvores em amostras diferentes e tira a média — os erros individuais se cancelam.

O **gradient boosting**, família do XGBoost, faz algo mais esperto: treina uma árvore rasa, olha onde ela errou, e treina a próxima focada nesses erros. Cada árvore corrige o resíduo da anterior. Centenas de correções sucessivas produzem um modelo muito preciso.

É genuinamente uma das melhores ferramentas disponíveis para dado tabular. A pergunta deste capítulo não é se ela é boa — é o que ela precisa para ser melhor *naquele* problema.

§3 As três condições

Boosting ganha da logística quando pelo menos uma destas três coisas é verdadeira.

Existe interação relevante. Se o efeito de uma característica depende de outra, a árvore acha e a reta não.

Existe não linearidade. Se o risco sobe até certo ponto e depois cai, a reta não representa isso e a árvore representa.

Há dado suficiente. Modelo flexível precisa de exemplos para distinguir padrão de acaso. Com poucos positivos, a flexibilidade vira decoração do ruído.

No nosso problema, a terceira condição falhou de forma decisiva: **198 quebras no treino**. Para um modelo com centenas de árvores, isso é pouquíssima evidência.



Fig. 25.1 Os dois modelos nas três medidas que decidiram a escolha. Notebook 04, seção 4.7. As barras de AUC estão numa escala ampliada de 0,80 a 0,88 para tornar a diferença visível — ela é pequena.

NO CRONOS · POR QUE A LOGÍSTICA FICOU

Três motivos, em ordem de peso:

- **Ela não perde desempenho.** Empata no ROC AUC e ganha 17% no PR-AUC, que é a métrica que vale para evento raro. Não é uma troca de precisão por simplicidade.
- **Ela é explicável por construção.** A decomposição de cada caso é exata, sem ferramenta externa. Num produto em que o alerta precisa justificar-se para o analista, isso é requisito e não conforto.
- **Ela mantém a calibração.** Prevê 48,1 quebras onde ocorreram 50, o que permite somar probabilidades e sustentar a projeção do KPI.

O XGBoost permaneceu no notebook como baseline de comparação, e é isso que torna a escolha defensável. Sem ele, "usamos regressão logística" seria uma alegação; com ele, é um resultado.

NA VIDA REAL

Um carro de Fórmula 1 é incomparavelmente mais rápido que um popular. Numa rua de terra com buraco, o popular chega antes — e o de Fórmula 1 talvez não chegue.

Ninguém conclui daí que o carro de corrida é ruim. A conclusão é sobre a pista. Escolher modelo funciona igual: a pergunta não é qual é o melhor modelo, é qual é o melhor modelo *para este dado, com esta quantidade de evidência e este requisito de explicação*.

ATENÇÃO · COMECE PELO SIMPLES, MAS MEÇA

A moral não é "modelo simples é sempre melhor". É que a comparação precisa ser feita, e a ordem certa é começar pelo simples e só subir de complexidade se o número justificar.

O caminho oposto — começar pelo XGBoost porque é o que todo mundo usa — teria funcionado aqui: ele também entrega AUC de 0,868. E teria custado a explicabilidade e a calibração, sem que ninguém percebesse o que foi perdido, porque a métrica que aparece por padrão não mostra isso.

COMO PEDIR

"Roda o modelo simples primeiro e o complexo como comparação, na mesma validação, e me mostra os dois lado a lado. Se o ganho do complexo for pequeno, quero saber o que eu perco em explicabilidade e em calibração antes de trocar."

REVISÃO RÁPIDA

- Árvore é uma sequência de perguntas; captura interação de graça e decora quando cresce demais.
- Ensembles combinam muitas árvores: floresta tira média, boosting corrige o erro da anterior.
- Boosting ganha quando há interação, não linearidade ou dado abundante. No Cronos faltou dado: 198 quebras no treino.
- Resultado: empate no AUC, 17% de vantagem da logística no PR-AUC, mais explicabilidade e calibração.
- Comece pelo simples e só suba de complexidade quando o número justificar — mas sempre meça os dois.

CAPÍTULO XXVI

Índice composto: construir uma nota

quando não existe alvo para prever, mas existe uma pergunta para responder

Nem toda pergunta vira modelo. "Qual produto está pior?" não tem resposta certa registrada em lugar nenhum — não há coluna de gabarito. O que existe é um julgamento a ser construído, com critérios explícitos. Isso tem método próprio, e tem armadilhas próprias.

§1 O que é um índice composto

Índice composto é uma nota única construída a partir de vários indicadores diferentes, para permitir comparação e ranking. IDH, nota do Enem, score de crédito e nota de risco de fornecedor são todos índices compostos.

Ele não prevê nada. Ele *resume* um julgamento, e por isso a qualidade dele depende inteiramente da qualidade das decisões que entram na construção — decisões que são de negócio, não de estatística.

§2 As quatro decisões

Construir um índice honesto exige responder quatro perguntas, e escrever a resposta de cada uma.

Quais componentes entram. Devem cobrir dimensões diferentes do problema. Componentes que dizem a mesma coisa contam o mesmo fato duas vezes e distorcem o resultado sem que ninguém perceba.

Como normalizar. Taxa de violação vem em porcentagem, duração vem em horas, volume vem em contagem. Somar isso direto é somar laranja com metro. Ou você converte tudo para uma escala comum, ou usa a posição relativa de cada item.

Quanto cada um pesa. Não existe resposta técnica. Peso igual é a escolha honesta quando não há base para diferenciar — e ela precisa ser declarada como escolha, não apresentada como neutralidade.

Quem entra no ranking. Um produto com 12 incidentes pode ter taxa de violação de 8% por causa de um único caso. Definir um volume mínimo evita que o topo e o fundo do ranking sejam ocupados por ruído.

NA VIDA REAL

O IDH resume três coisas — saúde, educação e renda — num número entre 0 e 1, e a escolha de dar peso igual às três é uma decisão política disfarçada de fórmula.

Ninguém demonstrou que educação vale exatamente o mesmo que renda. Alguém decidiu, escreveu a decisão, e o índice ficou útil justamente porque a regra é pública e estável. É o que permite comparar países e acompanhar ao longo do tempo.

Um índice cuja fórmula não é publicada não é um índice: é uma opinião com casas decimais.

§3 Redundância e sensibilidade: os dois testes obrigatórios

Duas verificações separam um índice construído de um índice inventado.

O **teste de redundância** mede a correlação entre os componentes. Se dois deles andam quase sempre juntos, um dos dois deve sair — senão aquela dimensão entra com peso dobrado sem que a fórmula diga isso.

O **teste de sensibilidade** pergunta o quanto o ranking muda se os pesos mudarem. Se dobrar o peso de um componente vira o ranking de cabeça para baixo, a nota é frágil e a escolha de peso passa a ser a coisa mais importante do índice — o que é péssimo, porque ela é arbitrária.

Notebook 07, seções 4.2 e 4.6.

NO CRONOS · O SCORE DE SAÚDE POR PRODUTO

A nota resume cinco componentes: taxa de violação de OLA, proporção de problemas inéditos, proporção sem causa identificada, duração mediana e tendência.

- **Redundância:** duração mediana e incidentes por ativo tinham correlação de **0,85**. O segundo saiu.
- **Normalização por posição relativa**, não por valor absoluto, porque não existe valor de referência oficial por componente. A nota compara produtos entre si, e isso está declarado.
- **Peso igual** entre os cinco, por ausência de base para diferenciar.
- **Sensibilidade:** dobrar o peso de qualquer componente preserva de 90% a 94% da ordem, e em nenhum caso muda o pior colocado. O ranking é estável.
- **Volume mínimo de 200 incidentes** em 2025 — restam 17 produtos, que cobrem 95% do volume e 219 das 238 violações.

§4 Por que a nota não é redundante com o modelo de risco

A pergunta natural é: já existe um modelo que estima risco por incidente, para que serve uma nota por produto?

A resposta tem duas partes, e a segunda é a interessante.

A primeira: a correlação entre a taxa de violação e a proporção de casos inéditos é de apenas 0,11, e a concordância entre a nota composta e um ranking feito só pela taxa de violação é de 70,6%. As duas ordenam diferente.

A segunda: o modelo de risco só pode usar informação disponível na abertura, por causa do vazamento. A nota descreve o passado, então pode usar código de fechamento, duração e status — campos que o

modelo é obrigado a excluir. Elas enxergam por janelas diferentes por construção.



O problema inédito viola o OLA 4,6 vezes mais que a rotina conhecida. Produto com muito inédito e pouca violação até agora é exposição acumulada, não segurança.

Fig. 26.1 Os 17 produtos do ranking, cruzando as duas dimensões que menos se correlacionam entre si ($r = 0,11$). O quadrante inferior direito é o achado que uma avaliação por incidente não produz.

COMO PEDIR

"Para construir a nota, escreve as quatro decisões — componentes, normalização, pesos e critério de entrada — e roda os dois testes: correlação entre componentes para achar redundância, e sensibilidade do ranking a mudança de peso. Se algum par passar de 0,8, tira um."

REVISÃO RÁPIDA

- Índice composto resume um julgamento; ele não prevê nada e depende das decisões declaradas.
- Quatro decisões: componentes, normalização, pesos e quem entra no ranking.
- Teste de redundância: componentes muito correlacionados contam o mesmo fato duas vezes. No Cronos, 0,85 eliminou um.
- Teste de sensibilidade: dobrar peso preservou 90% a 94% da ordem — nota estável.
- A nota não é redundante com o modelo de risco: ela pode usar campos de fechamento que o modelo é obrigado a excluir.

CAPÍTULO XXVII

Compor modelos sem extrapolar nenhum

a pergunta que nenhum dos dois modelos responde sozinho

A pergunta que o mentor da Locaweb disse ser a mais importante — vamos fechar o ano dentro da meta? — não é respondida pelo Prophet nem pelo modelo de risco. Ela é respondida por uma composição dos dois, montada de forma que nenhum deles seja usado fora do que sabe fazer.

§1 O erro de esticar um modelo

A saída preguiçosa seria pegar a taxa histórica de violação e multiplicar pelo volume previsto para o ano. Funciona como conta e ignora tudo que já se sabe: os incidentes que já aconteceram têm resultado conhecido, e os que estão abertos agora podem ser pontuados um a um.

A saída oposta, também errada, seria pedir ao modelo de risco que pontuasse os incidentes do ano inteiro. Ele não pode: incidentes que ainda não existem não têm produto, nem categoria, nem ativo. Não há o que pontuar.

§2 Decompor em parcelas

A solução é dividir o ano em três pedaços, cada um com o instrumento certo.



Fig. 27.1 As três parcelas somam exatamente o ano, sem sobreposição e sem buraco. Cada uma usa o instrumento adequado ao que ela é: contagem para o passado, modelo de risco para a fila viva, previsão de volume para o que ainda não existe.

O que torna a decomposição correta não é a elegância: é que *nenhum modelo é usado fora do domínio dele*. O modelo de risco pontua apenas

incidentes que existem. O Prophet prevê apenas volume, que é o que ele sabe fazer. E o passado não é modelado, é contado.

NA VIDA REAL

É como qualquer pessoa organizada fecha o orçamento do mês. Você soma o que já gastou — isso está no extrato, não se estima. Soma o que já está comprometido: a fatura do cartão que fecha semana que vem, cujo valor você já conhece. E estima o que ainda vai gastar até o dia 30.

Ninguém em sã consciência estimaria o mês inteiro pela média histórica, ignorando o extrato. E é exatamente isso que uma projeção feita só com taxa média faria.

§3 A parcela dominante decide a precisão

Um efeito importante da decomposição: conforme o ano avança, a parcela do passado cresce e as outras encolhem. Em 1º de outubro, ela já é de 70% a 76% do total.

Isso explica por que a projeção é razoavelmente precisa apesar de o modelo de volume ter erro alto. O erro de 45% na previsão de volume do P3 entra multiplicado por uma parcela que representa menos de um terço do total, e o resultado final erra 6,1%.

A lição é geral: numa composição, verifique *qual parcela domina*. Ela é a que merece atenção, e as outras podem tolerar erro maior do que parece.

Notebook 06, seções 4.5 e 4.6.

NO CRONOS · O QUE A VALIDAÇÃO EM DEZ PONTOS MOSTROU

Repetimos a projeção em cinco datas de corte, para as duas prioridades:

- **Erro abaixo de 7% em nove das dez projeções**, com máximo de 15,0%.
- **A situação em relação à meta foi acertada em 7 de 10** — cinco de cinco no P2 e duas de cinco no P3.
- **Os três erros do P3 são sistemáticos e explicados**: vêm da queda de volume de novembro e dezembro, que nenhuma informação anterior a outubro permitia antecipar.
- **Nenhum erro no sentido otimista**. Em nenhuma projeção o sistema indicou meta cumprida que depois não se confirmasse. Para uma ferramenta de alerta, errar sempre para o lado do susto é a direção certa.

ATENÇÃO · OTIMIZAR UMA PEÇA PIOROU O CONJUNTO

Este é o resultado mais contraintuitivo do projeto inteiro, e o mais útil de guardar.

Trocando a configuração do Prophet por outra que prevê volume bem melhor — o erro anual do P2 cai de 4,94% para 1,66% —, a projeção do KPI **piora**: o acerto da situação em relação à meta cai de 7 para 4 em 10, e a cobertura da faixa cai de 10 para 7.

A peça melhorou e o produto piorou. É por isso que a métrica que decide não pode ser a da peça: tem que ser a da saída final, medida ponta a ponta. Otimizar componentes isoladamente é uma das formas mais comuns de piorar um sistema com boa intenção.

COMO PEDIR

"Decompõe em parcelas de forma que nenhum modelo seja usado fora do domínio dele, e confirma que as parcelas somam o total sem sobreposição. Depois mede o erro da saída final, não o de cada peça — e me avisa se melhorar uma peça piorar o conjunto."

REVISÃO RÁPIDA

- Nem toda pergunta cabe num modelo. Compor é dividir a pergunta em pedaços com o instrumento certo em cada um.
- Três parcelas: o passado se conta, a fila viva se pontua, o futuro se prevê.
- Verifique qual parcela domina — ela decide a precisão do conjunto.
- No Cronos: erro abaixo de 7% em 9 de 10 projeções, situação correta em 7 de 10, nenhum erro otimista.
- Melhorar a previsão de volume piorou a projeção do KPI. Meça sempre a saída final.

VII

PARTE SÉTIMA

O rigor e o pedido

xxviii Hipótese, teste e o valor do resultado negativo

xxix Reprodutibilidade

xxx Da pergunta ao método

CAPÍTULO XXVIII

Hipótese, teste e o valor do resultado negativo

correlação, causa, e o que fazer quando o dado diz não

Duas das três hipóteses centrais do Cronos foram refutadas pelo próprio dado — inclusive uma levantada pelo mentor da Locaweb. Testar e reportar o resultado negativo, em vez de silenciar, é o que separa análise de propaganda. Este capítulo trata das ferramentas para isso.

§1 Correlação em três números

Correlação mede se duas coisas andam juntas. O coeficiente **r** vai de -1 a 1 : positivo significa que sobem juntas, negativo que uma sobe quando a outra desce, zero que não há relação linear.

O segundo número é o **R²**, que é simplesmente **r** ao quadrado, e tem uma leitura muito mais útil: *que fração da variação de uma é explicada pela outra*. Um **r** de $0,159$ parece uma relação; o **R²** correspondente é $0,025$, ou seja, $2,5\%$. O quadrado desinfla a impressão, e é por isso que ele deve ser reportado.

O terceiro é o **p-valor**, e ele responde uma pergunta diferente das outras duas: qual a chance de eu ver uma relação desse tamanho se, na verdade, não houvesse relação nenhuma? Um **p** de $0,011$ significa cerca de 1% de chance. Ele diz que a relação provavelmente existe — e não diz nada sobre ela ser grande ou útil.

ATENÇÃO · SIGNIFICANTE NÃO QUER DIZER IMPORTANTE

É a confusão mais comum em análise de dados, e ela tem uma causa simples: com amostra grande, quase tudo vira estatisticamente significativo.

Com 255 dias úteis, uma relação que explica $2,5\%$ da variação já aparece com **p** de $0,011$. O **p-valor** está certo: a relação existe. E ela é fraca a ponto de não sustentar decisão nenhuma.

Sempre leia os três juntos. O **p** diz se existe, o **r** diz a direção, o **R²** diz se importa.


§2 **Correlação não é causa, e a razão é o confundidor**

A frase é repetida até virar clichê e raramente é explicada. O mecanismo tem nome: **confundidor**, uma terceira variável que causa as duas e cria a aparência de ligação entre elas.

O QUE PARECE



O QUE É



Proibir sorvete não salva ninguém. O teste que revela isso é controlar pelo confundidor: dentro dos dias de mesma temperatura, a relação some.

Fig. 28.1 O confundidor clássico. A defesa contra ele é sempre a mesma: comparar dentro de grupos em que o suspeito está fixo — o que se chama controlar pela variável.

NO CRONOS · UM GRADIENTE QUE SOBREVIVEU AO CONTROLE

A análise de recorrência mostrou que incidentes com descrição inédita violam o OLA **4,6 vezes mais** que problemas rotineiros: 1,60% contra 0,35%. A faixa de casos inéditos é 37% da base e concentra 61% das quebras.

Antes de acreditar, testamos dois confundidores plausíveis. Talvez inédito fosse só um jeito indireto de dizer "prioridade alta". Talvez fosse só "aberto manualmente". Controlando por cada um deles — comparando dentro de cada prioridade e dentro de cada origem — o gradiente permaneceu.

Testamos também se a conclusão dependia da forma de normalizar o texto das descrições: com três critérios diferentes, o gradiente ficou em 3,9x, 4,6x e 4,3x. A conclusão não é artefato da escolha de limpeza.

Notebook 05, seções 4.4.1, 4.5 e 4.6.

§3 Resultado negativo é resultado

Uma hipótese testada e refutada é conhecimento produzido. Ela fecha um caminho, economiza esforço e, numa defesa, demonstra método — porque mostra que as afirmações que *sobraram* passaram por um filtro.

O incentivo, porém, é sempre o contrário: quem levantou a hipótese não quer que ela caia, e a saída fácil é não testar.

NO CRONOS · DUAS HIPÓTESES DERRUBADAS, UMA DELAS DO MENTOR

- **A cascata.** As Sprints 1 e 2 venderam um detector de incidentes que escalam até virar um grande. No dado, 87% das quebras são de incidentes isolados, e a taxa de escalada é de 21% contra cerca de 60% que o acaso produziria. Era um dos diferenciais do produto, e saiu.
- **O acúmulo.** O mentor da Locaweb descreveu, em mentoria, um padrão de backlog acumulado derrubando o OLA. Medimos o backlog diário contra as quebras: $r = -0,139$, com Spearman de $-0,115$. Relação levemente negativa e fraca. Testada também com defasagem de 1 a 3 dias, mesmo resultado.
- **O volume prevê a quebra?** $r = +0,159$ e $R^2 = 0,025$. A relação existe, é significativa, e explica 2,5% da variação. Foi essa medição que reposicionou os dois modelos: volume dimensiona carga, o modelo de risco aponta o caso.

Vale reparar na formulação do segundo item. Não escrevemos "o acúmulo não existe". Escrevemos que o backlog agregado por dia não prevê quebra *na base disponível*. O efeito pode existir num recorte que o dado não expressa — por equipe, por capacidade instalada. Reportar o resultado negativo com o escopo correto é diferente de negar a experiência de quem opera.

NA VIDA REAL

Um remédio parece funcionar porque quem o toma vive mais. Só que quem toma é quem procura médico, e quem procura médico já se cuida mais. O confundidor é o cuidado com a saúde, e ele produz sozinho os dois efeitos.

É por isso que o padrão-ouro na medicina é o sorteio: se você decide por sorteio quem toma o remédio, o cuidado com a saúde fica igualmente distribuído nos dois grupos e para de confundir. Quando não dá para sortear — e em dado de operação nunca dá — sobra controlar pelas variáveis que você consegue medir, sabendo que as que você não mediu continuam lá.

COMO PEDIR

"Sempre que apresentar uma correlação, me dá r , R^2 e p juntos, e me diz qual das três é a notícia. Antes de concluir, testa pelo menos dois confundidores plausíveis controlando por eles. E se a hipótese cair, escreve que caiu, com o escopo do que foi testado."

REVISÃO RÁPIDA

- r dá direção e força; R^2 dá a fração explicada; p diz se a relação provavelmente existe.
- Com amostra grande quase tudo é significativo. Significativo não é importante.
- Confundidor é a terceira variável que causa as duas. Defesa: controlar, comparando dentro de grupos.
- No Cronos: cascata refutada (87% isoladas), acúmulo refutado ($r = -0,139$), volume $\times$ quebra fraco ($R^2 = 0,025$).
- Reporte o resultado negativo com o escopo do que foi testado, não como negação absoluta.

CAPÍTULO XXIX

Reprodutibilidade

todo número precisa da célula que o produz

Um número que ninguém consegue refazer não é um resultado: é uma alegação. Este é o capítulo mais chato do livro e o que mais economiza vergonha, porque a auditoria do próprio projeto encontrou números em slide que nenhum código produzia.

§1 A regra

Todo número que aparece em texto, slide ou tela precisa ter uma célula de código que o produza, a partir dos dados brutos, rodando do zero.

Parece burocracia até a primeira vez que alguém pergunta de onde veio o número e a resposta é "eu calculei uma vez, num notebook que eu não salvei".

NO CRONOS · O QUE A AUDITORIA ENCONTROU

- **Números de tela sem origem.** A tela do MVP exibia "os 5% de maior risco concentram 48% das quebras" e um painel de fatores, numa época em que o modelo de risco ainda não existia. Eram maquete apresentada como resultado.
- **Gráficos com alturas escritas à mão.** Um gráfico rotulado "volume mensal" mostrava doze barras subindo suavemente, quando a série real é plana até agosto. O gráfico decorativo contradizia a descoberta central do próprio deck.
- **Testes em notebook de laboratório não versionado.** Os números da cascata (87%, 21%) e da clusterização (silhueta 0,13) foram produzidos em notebook fora do controle de versão. São resultados verdadeiros sem código que os reproduza — o que, para efeito de defesa, é a mesma coisa que não ter.

§2 Quando o próprio método não é determinístico

Existe um caso em que a reprodução exata é impossível por construção: quando o algoritmo tem componente aleatório. O ajuste do Prophet parte de uma inicialização aleatória, então duas execuções do mesmo código, sobre o mesmo dado, dão resultados levemente diferentes.

Há duas saídas. Fixar a semente aleatória torna a execução repetível, e cria a ilusão de precisão — o número passa a parecer exato quando na verdade é um sorteio congelado.

A outra é reportar em **faixa**. Foi a adotada: a cobertura da banda de 80% aparece como "entre 86% e 88%" no P2 e "entre 59% e 61%" no P3, com o valor exato de cada execução ficando apenas na saída da célula. É menos elegante e é honesto.

ATENÇÃO · A ASSINATURA DE UM NÚMERO INVENTADO

Três sinais que denunciam número sem origem, e que valem para qualquer material que você receba, inclusive de mim:

- **Precisão desproporcional.** "48,3% das quebras" calculado sobre 50 casos. Com 50 casos, a casa decimal não existe.
- **Números redondos demais.** Percentuais que caem todos em múltiplos de 5 costumam ser estimativa apresentada como medição.
- **O mesmo fato com dois valores.** Se o AUC aparece como 0,79 num parágrafo e 0,81 em outro, pelo menos um dos dois não veio de código.

§3 As práticas que resolvem

Poucas coisas, e todas baratas.

Notebook comitado executado, com as saídas preservadas. Célula sem saída é promessa.

Invariantes travados por asserção. No notebook da base, os números do filtro estão travados com `assert`: se a base mudar, o notebook quebra em vez de mudar o número em silêncio. Erro de recorte é silencioso por natureza, e essa é a defesa.

Figura gerada, nunca desenhada. Todo gráfico sai de código sobre

os dados. Gráfico decorativo, se existir, precisa ser rotulado como esquema.

Cadeia de origem declarada: qual arquivo bruto, qual filtro, qual notebook, qual saída. Assim qualquer número pode ser rastreado até a planilha original.

NA VIDA REAL

É a diferença entre uma receita e uma comida boa. A comida boa que só a avó sabe fazer morre com ela. A receita escrita — quantidades, tempos, ordem — atravessa gerações e pode ser conferida por quem duvidar.

Análise sem código que a reproduza é a comida da avó: pode ter sido ótima, e ninguém consegue refazer nem verificar.

COMO PEDIR

"Todo número que você escrever em texto precisa ter a célula que o produz, e o notebook vai comitado com as saídas. Trava os números-chave com asserção. Se o método tiver aleatoriedade, reporta faixa em vez de valor exato — e me avisa que tem aleatoriedade."

REVISÃO RÁPIDA

- Número sem célula que o produza é alegação, não resultado.
- A auditoria do Cronos achou números de tela sem modelo por trás e gráficos com alturas escritas à mão.
- Método não determinístico se reporta em faixa; fixar semente cria falsa precisão.
- Sinais de número inventado: precisão desproporcional, redondo demais, o mesmo fato com dois valores.
- Práticas: notebook executado e comitado, invariantes com asserção, figura gerada por código, cadeia de origem declarada.

CAPÍTULO XXX

Da pergunta ao método

a página que responde ao objetivo deste livro

Todo o resto do livro existe para sustentar estas duas páginas. Aqui está o mapa: dada uma pergunta, qual família de método responde, o que é preciso ter em mãos e qual é a armadilha característica dela.

§1 O mapa

Comece pela forma da pergunta. Ela determina quase tudo o que vem depois.

SE A PERGUNTA É...	O MÉTODO É	A ARMADILHA
Quanto / quantos vai acontecer, ao longo do tempo	previsão de série temporal	validar embaralhando · cap. XIV
Qual caso vai acontecer o evento	classificação	vazamento · cap. XVII
Quanto vale este caso (valor contínuo)	regressão	confundir erro com incerteza · cap. XIII
Quem se parece com quem	clusterização	grupo que não existe · cap. XXIV
Qual está pior , sem gabarito	índice composto	componentes redundantes · cap. XXVI
Isto causa aquilo?	teste de hipótese com controle	confundidor · cap. XXVIII
Onde está concentrado	análise descritiva	régua trivial forte · cap. VI
Vamos bater a meta?	composição de modelos	extrapolar um modelo · cap. XXVII

§2 As sete perguntas que evitam quase todo retrabalho

Antes de qualquer análise começar, sete perguntas cobrem a maior parte do que costuma dar errado. Elas estão em ordem: cada uma só faz sentido depois da anterior.

1 · Qual decisão muda com essa resposta? se não muda nenhuma, pare aqui — cap. I
2 · Qual é a linha da tabela, e quais linhas entram? granularidade e recorte definem sobre quem você está falando — cap. III
3 · A base mudou de comportamento no meio do período? mudança de regime tem que ser achada antes de desenhar a validação — cap. VIII
4 · Quais colunas existem no instante da decisão? o resto é vazamento, por mais que ajude — cap. XVII
5 · Qual é o resultado sem modelo nenhum? o baseline, ou a regra que a operação já usa — caps. XI e XXII
6 · Qual métrica decide, e por quê? acurácia quase nunca; em evento raro, PR-AUC e curva de ganho — caps. XIX e XXI
7 · Contra qual período isso foi validado? corte por data, sempre; e o protocolo rotulado ao lado do número — cap. XIV

As quatro primeiras são sobre o dado e valem para qualquer análise. As três últimas são sobre a prova.

Fig. 30.1 O roteiro completo. Nenhuma dessas perguntas é técnica: todas podem ser feitas por quem não vai escrever o código, e é exatamente esse o ponto.

§3 Os pedidos que mudam o resultado

Reunidos das caixas *Como pedir* espalhadas pelo livro, os que mais mudam a qualidade do que você recebe de volta:

ANTES DE MODELAR <i>"Me diz qual decisão muda com essa resposta. Depois a granularidade da linha, quantos registros sobram após cada filtro, e se existe salto de patamar na série."</i>
AO ESCOLHER O MÉTODO <i>"Roda o baseline e o modelo simples primeiro, na mesma validação, e me mostra os dois lado a lado. Só sobe de complexidade se o número justificar — e me diz o que eu perco em explicabilidade e calibração."</i>

AO AVALIAR

"Nada de acurácia em evento raro. Quero prevalência, PR-AUC com a taxa base ao lado, matriz de confusão em três cortes e a curva de ganho contra a regra que a operação já usa."

AO RECEBER O RESULTADO

"Cada número com a célula que o produz e o protocolo de validação rotulado ao lado. Se algo tiver aleatoriedade, reporta faixa. E se alguma hipótese caiu, escreve que caiu."

§4 A última coisa

Se este livro couber numa frase, é esta: *a parte difícil quase nunca é o algoritmo.*

Foi assim em todo ponto do Cronos. O que decidiu o projeto foi escolher a população certa, notar que a base mudou de regime em setembro, proibir quatro colunas que teriam feito o modelo parecer excelente, medir contra a régua certa em vez da conveniente, e reportar as hipóteses que caíram.

Nenhuma dessas decisões é sobre qual biblioteca usar. Todas são sobre entender o que se está perguntando — e é justamente por isso que elas ficam com você, e não comigo.

REVISÃO RÁPIDA

- A forma da pergunta determina a família do método, e cada família tem uma armadilha característica.
- Sete perguntas antes de começar: decisão, granularidade e recorte, mudança de regime, vazamento, baseline, métrica, validação.
- As quatro primeiras são sobre o dado; as três últimas são sobre a prova.
- Nenhuma delas é técnica, e todas podem ser feitas por quem não vai escrever o código.
- A parte difícil quase nunca é o algoritmo.